

## Zbiory rozmyte

### Zbiory ostre

Przyjmijmy, że  $U$  jest przestrzenią rozważanych obiektów.  
Zbiorem ostrym nazywamy taki zbiór, który charakteryzuje następująca zależność:

$$\mu_w : U \Rightarrow \{0,1\}$$

gdzie indeks  $w$  oznacza zbiór obiektów.

Niech  $A$  oznacza zbiór odpowiadający pewnej właściwości. Funkcja przynależności jest wówczas określona następująco:

$$\forall_{u \in U} \mu_A(u) = \begin{cases} 1 & \text{dla } u \in A \\ 0 & \text{dla } u \notin A \end{cases}$$

### Zbiory rozmyte

Lotfi Zadeh (1965)

Zbiorem rozmytym jest taki zbiór obiektów, gdzie poszczególne elementy mogą w pełni należeć do tego zbioru, wcale nie należeć lub należeć w pewnym stopniu.

$$A = \{(x, \mu_A(x)) : x \in X, \mu_A(x) \in [0,1]\}$$

Notacja zbioru rozmytego:

$$\mu_A | x$$

Przykładowa funkcja przynależności dla zbioru wysoka temperatura (WT) dająca zbiór rozmyty przedstawia się następująco:

$$WT = \{(u, \mu_{WT}(u)) | u \in \mathfrak{R}\}$$

$$\mu_{WT}(u) = \begin{cases} 0 & \text{dla } u \leq 1 \\ \frac{(u-1)^2}{u^2 - u} & \text{dla } u > 1 \end{cases}$$

### Zbiory rozmyte - terminologia

- Zbiór konwencjonalne (dystrybutywne) – zbiory ostre (*crisp set*)
- Nośnik (*support*) zbioru rozmytego – zbiór ostry złożony z tych elementów uniwersum, które należą tego zbioru rozmytego w niezerowym stopniu:

$$A = \text{supp} \{x : \mu_A(x) > 0\}$$

- Pusty zbiór rozmyty – żaden element uniwersum nie należy do tego zbioru (nośnik zbioru pustego jest pustym zbiorem ostrym)
- Punkt rozgraniczenia (*crossover point*) – taki element  $x$  zbioru rozmytego  $A$ , że:  $\mu_A(x) = 0.5$
- Jądro (*kernel*) lub nukleus (*nucleus*) zbioru rozmytego  $A$  – zbiór ostry tych elementów, które w pełni należą do  $A$  (należą w stopniu równym 1) (oznaczenie:  $\text{ker}(A)$ )

### Zbiory rozmyte - terminologia

- Wysokość zbioru rozmytego (*height*) – liczba będąca supremum wartości funkcji przynależności zbioru rozmytego  $A$


$$\text{hgt}(A) = \sup \mu_A(x)$$

- Zbiór rozmyty normalny – wysokość wynosi 1. Normalizacja zbioru polega na podzieleniu funkcji przynależności przez wysokość zbioru.

### Klasy funkcji przynależności


- funkcje klasy I:

$$\Gamma_{a,b}(u) = \begin{cases} 0 & \text{dla } u \leq a \\ \frac{u-a}{b-a} & \text{dla } a < u \leq b \\ 1 & \text{dla } u > b \end{cases}$$



- funkcje klasy L:


$$L_{a,b}(u) = \begin{cases} 1 & \text{dla } u \leq a \\ \frac{b-u}{b-a} & \text{dla } a < u \leq b \\ 0 & \text{dla } u > b \end{cases}$$



## Klasy funkcji przynależności


- funkcje klasy  $\Lambda$ :

$$\Lambda_{a,b,c}(u) = \begin{cases} 0 & \text{dla } u \leq a \vee u \geq c \\ \frac{u-a}{b-a} & \text{dla } a < u \leq b \\ \frac{c-u}{c-b} & \text{dla } b < u < c \\ 0 & \text{dla } b < u < c \end{cases}$$



- funkcje klasy  $\Pi$ :


$$\Pi_{a,b,c,d}(u) = \begin{cases} 0 & \text{dla } u \leq a \vee u \geq d \\ \frac{u-a}{b-a} & \text{dla } a < u \leq b \\ 1 & \text{dla } b < u < c \\ \frac{d-u}{d-c} & \text{dla } c < u < d \end{cases}$$



## Klasy funkcji przynależności

- funkcje klasy  $V$ :


$$V_{a,b,c}(u) = 1 - \Lambda_{a,b,c}(u)$$



## Klasy funkcji przynależności

- funkcje klasy  $U$ :


$$U_{a,b,c,d}(u) = 1 - \Pi_{a,b,c,d}(u)$$



## Klasy funkcji przynależności


- funkcje klasy  $S$ :

$$S_{a,b}(u) = \begin{cases} 0 & \text{dla } u \leq a \\ 2 \cdot \left( \frac{u-a}{b-a} \right)^2 & \text{dla } a < u \leq \frac{a+b}{2} \\ 1 - 2 \cdot \left( \frac{u-b}{b-a} \right)^2 & \text{dla } \frac{a+b}{2} < u < b \\ 1 & \text{dla } u \geq b \end{cases}$$



- funkcje klasy  $\pi$ :


$$\pi_{b,c}(u) = \begin{cases} s_{c-b,c}(u) & \text{dla } u < c \\ 1 - s_{c,c+b}(u) & \text{dla } u \geq c \end{cases}$$



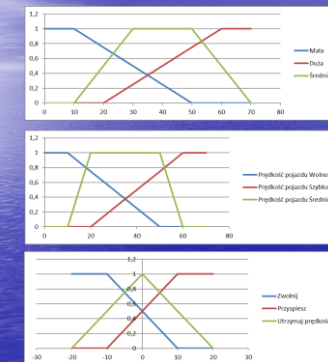
## Klasy funkcji przynależności

- funkcje klasy  $Z$ :


$$z_{a,b}(u) = 1 - s_{a,b}(u) = \begin{cases} 1 & \text{dla } u \leq a \\ 1 - 2 \cdot \left( \frac{u-a}{b-a} \right)^2 & \text{dla } a < u \leq \frac{a+b}{2} \\ 2 \cdot \left( \frac{u-b}{b-a} \right)^2 & \text{dla } \frac{a+b}{2} < u < b \\ 1 & \text{dla } u \geq b \end{cases}$$



## Przykład wykorzystania funkcji przynależności



## Przykład wykorzystania funkcji przynależności



## Podstawowe operacje mnogościowe na zbiorach

- dopełnienie

$$\mu_{\neg A}(x) = 1 - \mu_A(x)$$

- suma

$$\mu_{A \cup B}(x) = \mu_A(x) \vee \mu_B(x) \text{ (Max)}$$

- iloczyn

$$\mu_{A \cap B}(x) = \mu_A(x) \wedge \mu_B(x) \text{ (Min)}$$

- różnica

$$\mu_{A \setminus B}(x) = \min(\mu_A(x), 1 - \mu_B(x))$$

## Właściwości zbiorów rozmytych

- wypukłość

$$\mu_A(\lambda x_1 + (1 - \lambda)x_2) \geq \min(\mu_A(x_1), \mu_A(x_2))$$

- wklęsłość

$$\mu_A(\lambda x_1 + (1 - \lambda)x_2) \leq \max(\mu_A(x_1), \mu_A(x_2))$$

## Własności zbiorów

- jeśli A jest wklęsłe to dopełnienie jest wypukłe
- funkcja monotoniczna jest wypukła i wklęsła
- moc zbioru rozmytego

$$|A| = \sum_{i=1}^n \mu_A(x_i)$$

- relatywna moc zbioru

$$\|A\| = \frac{|A|}{|X|} \Rightarrow \|A\| = \frac{1}{n} \sum_{i=1}^n \mu_A(x_i)$$

## Własności zbiorów rozmytych

- równość  $A=B$ , jeśli:

$$\mu_A(x) = \mu_B(x)$$

- zawieranie się zbiorów rozmytych  $A \subseteq B$ :

$$\forall_{x \in U} \mu_A(x) \leq \mu_B(x)$$

## Liczba rozmyta

Liczbą rozmytą typu  $L$  nazwiemy wypukły i znormalizowany zbiór rozmyty z przestrzeni  $R$  taki, że istnieje dokładnie jedno

$$x_0 \in \mathfrak{R}, \mu_{L_1}(x_0) = 1$$

$x_0$  jest nazywane średnią wartością  $L$  (są również rozważane przypadki, dla których  $x_0$  jest przedziałem).

## Rozmytość a prawdopodobieństwo

Interpretacje prawdopodobieństwa:

- Prawdopodobieństwo jest własnością zdarzeń i reprezentuje częstość z jaką zdarzenie te zachodzą.
- Interpretacja logiczna – iloraz liczby zdarzeń należących do danego zdania w stosunku do liczby wszystkich zdarzeń.
- Interpretacja subiektywna – stopień przekonania o prawdziwości zdania.

## Rozmytość a prawdopodobieństwo

1. Zdarzenia to zbiory ostre natomiast niepewność dotyczy przypadkowości zajścia danego zdarzenia.
2. Rozmytość to niepewność związana z określeniem przynależności danego elementu do zbioru.
3. Prawdopodobieństwo charakteryzuje się addytywnością do maksymalnej wartości.
4. Rozmytość to ocena – brak wymagań dotyczących addytywności i unormowania.

## Prawdopodobieństwo zdarzenia rozmytego

Prawdopodobieństwo zdarzenia rozmytego:

$$p(A) = \sum_{\omega \in \Omega} P(\omega) \cdot \mu_A(\omega)$$

gdzie  $P(\omega)$  jest prawdopodobieństwem zdarzenia elementarnego.

## Metody procesu defuzyfikacji

- Metoda maksimum funkcji przynależności
- Metoda środka ciężkości
- Metoda średniej ważonej maksimów

## Metoda maksimum funkcji przynależności

- Metoda ta może być stosowana dla unimodalnych funkcji przynależności.
- Ten sposób wyznaczania wartości wyjściowej nie uwzględnia kształtu funkcji przynależności.

$$\mu(u_o) = \sup_{u \in U} \mu(u)$$

## Metoda wyznaczania środka ciężkości (ang. center of gravity, center of area)

Wartość wyjściowa wyznaczana jest jako środek ciężkości figury opisanej funkcją przynależności  $\mu(u)$

$$u_{COG} = \frac{\int \mu_A(u) u du}{\int \mu_A(u) du}$$

W przypadku dyskretnym:

$$u_{COG} = \frac{\sum_{k=1}^N \mu_A(u_k) u_k}{\sum_{k=1}^N \mu_A(u_k)}$$



## Przybliżona reprezentacja wiedzy (niepewna reprezentacja wiedzy)

Wnioskowanie przybliżone polega na stosowaniu:

- Dokładnych reguł i przybliżonych przesłanek
- Przybliżonych reguł i dokładnych przesłanek
- Przybliżonych reguł i przybliżonych przesłanek  
(wnioskowanie dokładne: dokładne reguły i dokładne przesłanki)

Źródła niepewności:

- Losowość uwzględnianych zdarzeń
- Odchylenia pomiarowe
- Istnienie ukrytych cech (pomijanych) lub parametrów powodujących losowy charakter zjawisk opisywanych niekompletnym zbiorem zmiennych
- Brak odpowiedniej wiedzy lub występujące w niej sprzeczności

## Etapy zastosowania wnioskowania przybliżonego

Metody określania:

- niepewności stwierdzeń przybliżonych
- niepewności przybliżonych reguł wnioskowania
- niepewności przesłanek złożonych z kilku stwierdzeń przybliżonych
- niepewności konkluzji wynikających z przybliżonych przesłanek i przybliżonych reguł
- niepewności konkluzji wyznaczanej za pomocą kilku niezależnych reguł przybliżonych

## Algorytm wnioskowania rozmytego

1. Wyznacz wartości funkcji przynależności dla poszczególnych pojęć rozmytych występujących w warunkach reguł.
2. Na podstawie funkcji przynależności wyznacz obszary rozmyte odpowiadające zmiennej zawartej w konkluzji reguły.
3. Dokonaj zestawienia obszarów rozmytych wyznaczonych w punkcie 2.
4. Na podstawie otrzymanych obszarów rozmytych, wyznacz wynikowy obszar rozmyty.
5. Dokonaj defuzyfikacji wynikowego obszaru rozmytego.

## Podstawowe operacje mnogościowe na zbiorach

• dopełnienie

$$\mu_{\neg A}(x) = 1 - \mu_A(x)$$

• suma

$$\mu_{A \cup B}(x) = \mu_A(x) \vee \mu_B(x)$$

• iloczyn

$$\mu_{A \cap B}(x) = \mu_A(x) \wedge \mu_B(x)$$

• różnica

$$\mu_{A \setminus B}(x) = \min(\mu_A(x), 1 - \mu_B(x))$$

## Operacje algebraiczne

• iloczyn

$$\mu_{A \circ B}(x) = \mu_A(x) \cdot \mu_B(x)$$

• suma

$$\mu_{A \oplus B}(x) = \mu_A(x) + \mu_B(x) - \mu_A(x) \cdot \mu_B(x)$$

• różnica

$$\mu_{A - B}(x) = \mu_A(x) \cdot (1 - \mu_B(x))$$

## Operacje logiczne

• iloczyn

$$\mu_{A \otimes B}(x) = \max(0, \mu_A(x) + \mu_B(x) - 1)$$

• suma

$$\mu_{A \oplus B}(x) = \min(1, \mu_A(x) + \mu_B(x))$$

• różnica

$$\mu_{A \ominus B}(x) = \max(0, \mu_A(x) - \mu_B(x))$$

## Operacje drastyczne

• iloczyn

$$\mu_{A \wedge B}(x) = \begin{cases} 0 & \text{dla } \mu_A < 1, \mu_B < 1 \\ \mu_A & \mu_B = 1 \\ \mu_B & \mu_A = 1 \end{cases}$$

• suma

$$\mu_{A \vee B}(x) = \begin{cases} 1 & \text{dla } \mu_A > 0, \mu_B > 0 \\ \mu_A & \mu_B = 0 \\ \mu_B & \mu_A = 0 \end{cases}$$

## Operacje drastyczne

• różnica

$$\mu_{A \dot{\wedge} B}(x) = \begin{cases} 0 & \text{dla } \mu_A < 1, \mu_B > 0 \\ \mu_A & \mu_B = 0 \\ 1 - \mu_B & \mu_A = 1 \end{cases}$$