

Literatura

1. Łachwa A.: Rozmyty świat zbiorów, liczb, relacji, faktów, reguł i decyzji, EXIT Warszawa 2001
2. Rutkowski L.: Metody i techniki sztucznej inteligencji. PWN, 2005

Operacje na zbiorach rozmytych

$$A = [0/1; 0.2/2; 0.5/3; 0.5/7; 0.6/8; 1/9; 0/10]$$



$$B = [1/1; 0.8/2; 0.7/3; 0.4/7; 0.3/8; \\ 0.1/9; 0/10]$$

Suma i iloczyn zbioru i jego dopełnienia



$$\mu_{\neg A}(x) = 1 - \mu_A(x)$$

$$\mu_{A \cup B}(x) = \mu_A(x) \vee \mu_B(x)$$





$$\mu_{A \cap B}(x) = \mu_A(x) \wedge \mu_B(x)$$



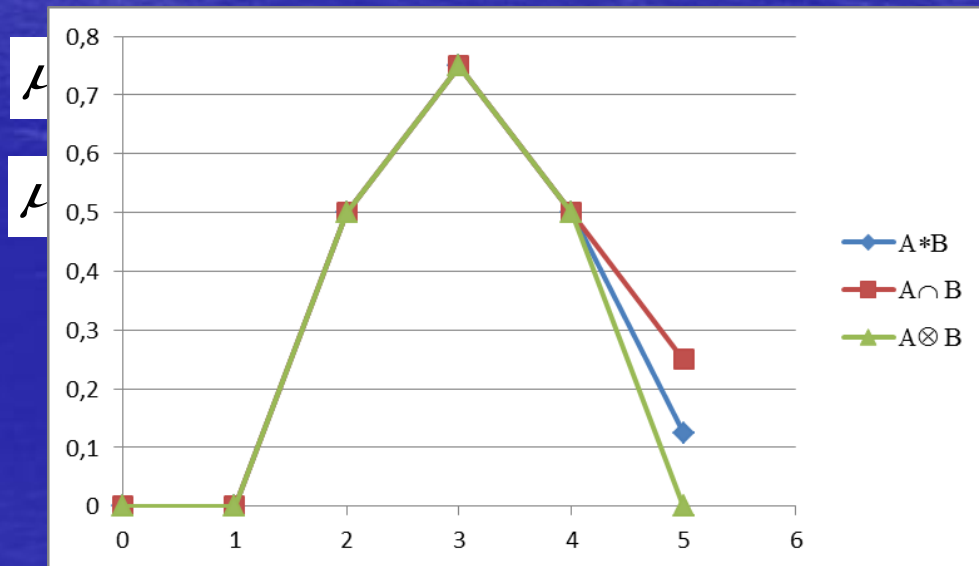



Obcinanie zbioru rozmytego







Porównanie sum algebraicznej, mnogościowej i logicznej




Porównanie iloczynu algebraicznego, mnogościowego i logicznego



Porównanie różnic algebraicznego, mnogościowego i logicznego



Przykład cel więziennych Van Neuta Lemke ^[1]



Jak łatwo światło dociera do więźnia ?

Jak łatwo może się on wydostać z więzienia ?



Liczby rozmyte

Definicja

Zbiór rozmyty A określony w zbiorze liczb rzeczywistych, $A \subseteq \mathbf{R}$, którego funkcja przynależności

$$\mu_A : \mathbf{R} \rightarrow [0,1]$$

spełnia warunki:

- zbiór rozmyty A jest normalny,
 - zbiór A jest wypukły,
 - $\mu_A(x)$ jest funkcją przedziałami ciągłą
- nazywamy liczbą rozmytą.

Liczby rozmyte


własności:

A – dodatnia niewłaściwa

B – płaska ujemna

C – właściwa mieszana

D i E – zbiory rozmyte nie będące liczbami



Podział i rodzaje liczb rozmytych

Liczba - właściwości

Właściwa rozmyta

Niewłaściwa

Płaska liczba rozmyta
(przedział rozmyty)

Liczba - znak

Dodatnie

Ujemne

Mieszane

Zasada rozszerzania

Zasada ta pozwala na wykorzystanie operacji arytmetycznych stosowanych w zbiorach ostrych na zbiory rozmyte.

Założenia: funkcja

$f: X \rightarrow Y,$

A – zbiór rozmyty w X

B – zbiór rozmyty w Y

Zbiór rozmyty B jest indukowany przez zastosowanie odwzorowania f na zbiorze A. Wtedy:

$$\mu_B = \sup_{x \in f^{-1}(y) \neq \emptyset} \mu_A(x), \quad y = f(x) \in Y$$

Podstawowe operacje arytmetyczne na liczbach rozmytych $A_1, A_2 \subseteq \mathbf{R}$:

dodawanie	$A_1 \oplus A_2 = B$	$\mu_B(y) = \sup_{\substack{x_1, x_2 \\ y=x_1+x_2}} \min\{\mu_{A_1}(x_1), \mu_{A_2}(x_2)\}$
odejmowanie	$A_1 \ominus A_2 = B$	$\mu_B(y) = \sup_{\substack{x_1, x_2 \\ y=x_1-x_2}} \min\{\mu_{A_1}(x_1), \mu_{A_2}(x_2)\}$
mnożenie	$A_1 \odot A_2 = B$	$\mu_B(y) = \sup_{\substack{x_1, x_2 \\ y=x_1 \cdot x_2}} \min\{\mu_{A_1}(x_1), \mu_{A_2}(x_2)\}$
dzielenie	$A_1 \oslash A_2 = B$	$\mu_B(y) = \sup_{\substack{x_1, x_2 \\ y=x_1/x_2}} \min\{\mu_{A_1}(x_1), \mu_{A_2}(x_2)\}$

Twierdzenie (Dubois i Prade)

Jeżeli liczby rozmyte A_1, A_2 mają ciągłe funkcje przynależności to wynikiem operacji arytmetycznych dodawania, odejmowania, mnożenia i dzielenia są liczby rozmyte.

Operacje jednoargumentowe przeprowadza się również za pomocą zasady rozszerzania.

Przykłady operacji jednoargumentowych:

1. Operacja zmiany znaku

$$\mu_{-A}(x) = \mu_A(-x)$$

Liczby rozmyte A i $-A$ są symetryczne względem osi x .

2. Operacja odwrotności

$$\mu_{A^{-1}}(x) = \mu_A(x^{-1})$$

Zakładamy, że A jest liczbą rozmytą dodatnią lub ujemną.

3. Operacja skalowania

$$\mu_{\lambda A}(x) = \mu_A(x\lambda^{-1})$$

4. Operacja eksponent

$$\mu_{e^A}(x) = \begin{cases} \mu_A(\log x) & \text{dla } x > 0 \\ 0 & \text{dla } x < 0 \end{cases}$$

Zatem e^A jest liczbą rozmytą dodatnią.

5. Operacja wartości bezwzględnej

$$\mu_{|A|}(x) = \begin{cases} \max(\mu_A(x), \mu_A(-x)) & \text{dla } x \geq 0 \\ 0 & \text{dla } x < 0 \end{cases}$$

$|A|$ jest liczbą rozmytą dodatnią.

Definicja liczby rozmytej typu L - P

Liczba rozmyta $A \subseteq \mathbb{R}$ jest liczbą rozmytą typu L - P

\Leftrightarrow

jej funkcja przynależności ma postać:

$$\mu_A(x) = \begin{cases} L\left(\frac{m-x}{\alpha}\right) & \text{jeżeli } x \leq m \\ P\left(\frac{x-m}{\beta}\right) & \text{jeżeli } x \geq m \end{cases}$$

gdzie:

m – liczba rzeczywista zwana wartością liczby rozmytej A ($\mu_A(m) = 1$),

α – liczba rzeczywista dodatnia zwana rozrzutem lewostronnym,

β – liczba rzeczywista dodatnia zwana rozrzutem prawostronnym,

natomiast L i P są funkcjami odwzorowującymi

$$(-\infty, \infty) \rightarrow [0, 1]$$

oraz spełniającymi warunki:

- $L(-x) = L(x), \quad P(-x) = P(x),$
- $L(0) = 1, \quad P(0) = 1,$
- L i P są funkcjami nierosnącymi w przedziale $[0, +\infty)$

W przypadku, gdy rozrzuty α i β zwiększają się, to liczba A staje się „bardziej” rozmyta.

Liczbę rozmytą typu L - P zapisuje się w postaci:

$$A = (m_A, \alpha_A, \beta_A)_{LP}$$

Zatem operacje arytmetyczne na liczbach rozmytych typu L - P sprowadzają się do operacji na jej parametrach.

Liczba rozmyta **przeciwna** do powyższej liczby rozmytej jest równa

$$-A = (-m_A, \alpha_A, \beta_A)_{LP}$$

Suma liczb rozmytych $A = (m_A, \alpha_A, \beta_A)_{LP}$ i $B = (m_B, \alpha_B, \beta_B)_{LP}$ ma postać

$$A \oplus B = (m_A + m_B, \alpha_A + \alpha_B, \beta_A + \beta_B)_{LP}$$

Definicja płaskiej liczby rozmytej L-P:

$$\mu_A(x) = \begin{cases} L\left(\frac{m-x}{\alpha}\right) & \text{jeżeli} \quad x \leq m_1 \\ 1 & \text{jeżeli} \quad m_1 \leq x \leq m_2 \\ P\left(\frac{x-m}{\beta}\right) & \text{jeżeli} \quad x \geq m_2 \end{cases}$$

Płaską liczbą rozmytą A możemy utożsamić z przedziałem rozmytym A postaci

$$A = (m_1, m_2, \alpha_A, \beta_A)_{LP}$$



Normy trójkątne

Ogólne podejście do operacji na zbiorach rozmytych

Iloczyn zbiorów można definiować za pomocą tzw. T-normy:

$$\mu_{A \cap B}(x) = T(\mu_A(x), \mu_B(x))$$

np. $T = \min(\mu_A(x), \mu_B(x))$

Sumę zbiorów rozmytych natomiast przez S-normę (*T-konormę*)

$$\mu_{A \cup B}(x) = S(\mu_A(x), \mu_B(x))$$

Np. $S = \max(\mu_A(x), \mu_B(x))$

Definicja T-normy

Odwzorowanie:

$$T : [0,1] \times [0,1] \rightarrow [0,1]$$

nazywamy *T*-normą, jeżeli funkcja *T* :

- jest monotoniczna:

$$T(a, c) \leq T(b, d) \quad \text{dla} \quad a \leq b \text{ i } c \leq d$$

- jest przemienna

$$T(a, b) = T(b, a)$$

- jest łączna

$$T(T(a, b), c) = T(a, T(b, c))$$

- spełnia warunki brzegowe

$$T(a, 0) = 0, \quad T(a, 1) = a$$

gdzie $a, b, c \in [0,1]$.

T -norma jest ograniczona tak, że:

$$T_d(a, b) \leq T(a, b) \leq \min(a, b)$$

gdzie T_d jest T -normą postaci

$$T_d(a, b) = \begin{cases} a & \text{gdy } b = 1 \\ b & \text{gdy } a = 1 \\ 0 & \text{gdy } a, b \neq 1 \end{cases}$$

T -normę oznacza się :

$$T(a, b) = a \overset{T}{*} b$$

Definicja S-normy

Odwzorowanie:

$$S : [0,1] \times [0,1] \rightarrow [0,1]$$

nazywamy S-normą, jeżeli funkcja S:

- jest monotoniczna:

$$S(a, c) \leq S(b, d) \quad \text{dla} \quad a \leq b \text{ i } c \leq d$$

- jest przemienna:

$$S(a, b) = S(b, a)$$

- jest łączna

$$S(S(a, b), c) = S(a, S(b, c))$$

- spełnia warunki brzegowe

$$S(a, 0) = a, \quad S(a, 1) = 1$$

gdzie $a, b, c \in [0,1]$.

S-norma jest ograniczona tak, że

$$\max(a, b) \leq S(a, b) \leq S_g(a, b)$$

gdzie S_w jest S-normą postaci

$$S_g(a, b) = \begin{cases} a & \text{gdy } b = 0 \\ b & \text{gdy } a = 0 \\ 1 & \text{gdy } a, b \neq 0 \end{cases}$$

S-normę oznacza się:

$$S(a, b) = a \overset{S}{*} b$$

T-normie odpowiada *S*-norma wg zależności:

$$a \overset{T}{*} b = 1 - \left[(1 - a) \overset{S}{*} (1 - b) \right]$$

***T*- oraz *S*-normy:**

Nr	$T(a, b)$	$S(a, b)$
1	$\min(a, b)$	$\max(a, b)$
2	ab	$a + b - ab$
3	$\max(a + b - 1, 0)$	$\min(a + b, 1)$

Relacje rozmyte

Relacje rozmyte

Relacja jest zdefiniowana na zbiorach ostrych i definiuje zbiór rozmyty:

$$\stackrel{def}{R} = \{((x, y), \mu_R(x, y)) : x \in X, y \in Y, \mu_R : X \times Y \rightarrow [0,1]\}$$

gdzie: X i Y – zbiory ostre.

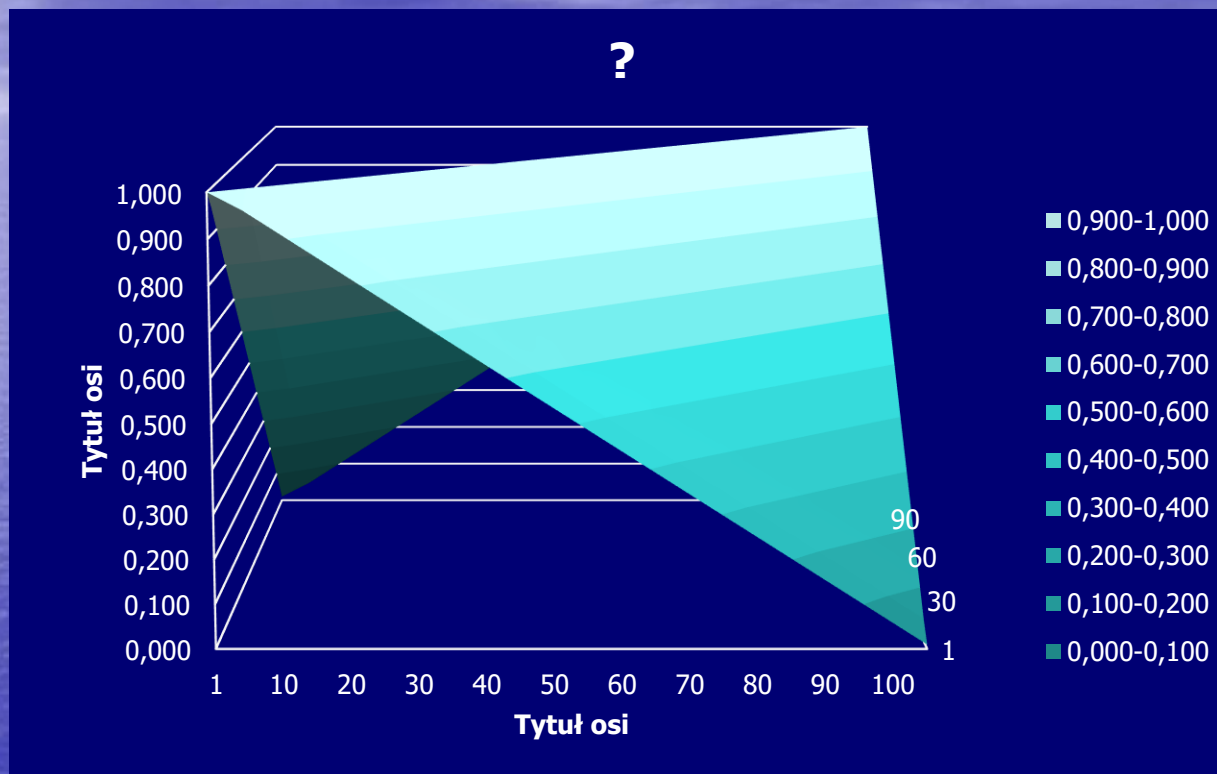
Przykład:

$$R = \begin{bmatrix} \mu_R(x_1, y_1) & \dots & \dots & \mu_R(x_1, y_m) \\ \mu_R(x_2, y_1) & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots \\ \mu_R(x_n, y_1) & \dots & \dots & \mu_R(x_n, y_m) \end{bmatrix}$$

Inna forma zapisu:

$$R = \sum_{X \times Y} \frac{\mu_R(x, y)}{(x, y)} \quad \text{lub} \quad R = \int_{X \times Y} \frac{\mu_R(x, y)}{(x, y)}$$

Przykład relacji rozmytej




$$\mu_R(x, y) = 1 - |w(x) - w(y)| / 100, \forall x, y \in R$$

Przykład relacji rozmytej dla zbiorów $A = \{3,4,5\}$ i $B = \{4,5,6\}$

Relacja $R \subset X \times Y$, która mówi: „B jest mniej więcej równe A”

A \ B	7	8	9
6	0,9	0,5	0,3
7	1	0,9	0,5
8	0,9	1	0,9

$$\mu_R(y) = \begin{cases} 1 & , \quad x = y \\ 0,9 & , \quad |x - y| = 1 \\ 0,5 & , \quad |x - y| = 2 \\ 0,3 & , \quad |x - y| = 3 \end{cases}$$



Złożenie relacji rozmytych A, B

Definicja

Złożeniem typu \sup - T relacji rozmytych $A \subseteq \mathbf{X} \times \mathbf{Y}$ i $B \subseteq \mathbf{Y} \times \mathbf{Z}$ nazywamy relację rozmytą $A \circ B \subseteq \mathbf{X} \times \mathbf{Z}$ o funkcji przynależności:

$$\mu_{A \circ B}(x, z) = \sup_{y \in \mathbf{Y}} \left\{ \left[\mu_A(x, y) \overset{T}{*} \mu_B(y, z) \right] \right\}$$

Konkretna postać funkcji przynależności $\mu_{A \circ B}(x, z)$ złożenia $A \circ B$ zależy od przyjętej T -normy.

Jeżeli jako T -normę przyjmujemy *min*, to otrzymamy złożenie typu *sup-min*

$$\mu_{A \circ B}(x, z) = \sup_{y \in \mathbf{Y}} \{ \min[\mu_A(x, y), \mu_B(y, z)] \}$$

Jeżeli zbiór \mathbf{Y} jest dyskretny, to sprowadza się to do postaci:

$$\mu_{A \circ B}(x, z) = \max_{y \in \mathbf{Y}} \{ \min[\mu_A(x, y), \mu_B(y, z)] \}$$

Przykład złożenia relacji rozmytych R i S

$X = \{1,2,3,4\}, Y = \{a,b,c\}, Z = \{\alpha, \beta, \chi, \delta, \varepsilon, \phi\}$

Relacja $R \subset X \times Y$, gdzie X jest w relacji z Y

R(x, y)	a	b	c
1	0,4	0,6	0,8
2	0,1	0,8	0,9
3	0,7	0,7	0,7
4	0,8	0,4	0,1

Relacja $R \circ S \subseteq X \times Z$

X\Z	α	β	χ	δ	ε	ϕ
1	0,4	0,3	0,8	0,6	0,4	0,2
2	0,2	0,3	0,9	0,6	0,3	0,2
3	0,6	0,3	0,7	0,6	0,5	0,2
4	0,6	0,3	0,4	0,4	0,5	0,1

Relacja S, gdzie Y jest w relacji z Z

S(y,z)	α	β	χ	δ	ε	ϕ
a	0,6	0,2	0,3	0,4	0,5	0,1
b	0,2	0,3	0,5	0,3	0,2	0,1
c	0,1	0,2	0,9	0,6	0,3	0,2

Podstawowe własności relacji rozmytych

I – macierz jednostkowa, O – macierz zerowa,
 A, B, C – relacje rozmyte

$$A \circ I = I \circ A = A$$

Element neutralny

$$A \circ O = O \circ A = O$$

Element zerowy

$$(A \circ B) \circ C = A \circ (B \circ C)$$

Łączność

$$A^m \circ A^n = A^{m+n}$$

Relacja potęg

$$(A^m)^n = A^{mn}$$

Potęgowanie

$$A \circ (B \cup C) = (A \circ B) \cup (A \circ C)$$

Rozdzielność względem \cup

$$A \circ (B \cap C) = (A \circ B) \cap (A \circ C)$$

Rozdzielność względem \cap

$$B \subset C \rightarrow A \circ B \subset B \circ C$$

Zawierania

Złożenie zbioru rozmytego z relacją rozmytą

Złożenie zbioru rozmytego

$$A \subseteq X$$

i relacji rozmytej

$$R \subseteq X \times Y$$

oznaczamy przez $A \circ R$ i definiujemy jako zbiór rozmyty $B \subseteq Y$:

$$B = A \circ R \quad \mu_B(y) = \sup_{x \in X} \left\{ \left[\mu_A(x)^T * \mu_R(x, y) \right] \right\}$$

T-norma oraz właściwości zbioru X określają postać funkcji $\mu_B(y)$:

$T(a, b)$	zbiór X	typ	$\mu_B(y)$
$\min(a, b)$	ciągły	sup-min	$\sup_{x \in X} \{ \min[\mu_A(x), \mu_R(x, y)] \}$
$\min(a, b)$	dyskretny	max-min	$\max_{x \in X} \{ \min[\mu_A(x), \mu_R(x, y)] \}$
$a \cdot b$	ciągły	sup-iloczyn	$\sup_{x \in X} \{ \mu_A(x) \cdot \mu_R(x, y) \}$
$a \cdot b$	dyskretny	max-iloczyn	$\max_{x \in X} \{ \mu_A(x) \cdot \mu_R(x, y) \}$

Przybliżone wnioskowanie

- **Modus ponens**

Założenia: A' , $A \rightarrow B$

$$B' = A' \circ (A \rightarrow B)$$

gdzie

$$\mu_{B'}(y) = \sup_{y \in Y} \left\{ \mu_{A'}(x) \overset{T}{*} \mu_{A \rightarrow B}(x, y) \right\}$$

- **Modus tollens**

Założenia: B' , $A \rightarrow B$

$$A' = (A \rightarrow B) \circ B'$$

gdzie

$$\mu_{A'}(x) = \sup_{y \in Y} \left\{ \mu_{A \rightarrow B}(x, y) \overset{T}{*} \mu_{B'}(y) \right\}$$

Modus ponens [2]

- $A' = A$
- $A' = \text{bardzo } A \Rightarrow$
- $A' = \text{mniej więcej } A,$
- $A' = \text{nie } A,$

$$\mu_{A'}(x) = \mu_A^2(x)$$

$$\mu_{A'}(x) = \mu_A^{\frac{1}{2}}(x)$$

$$\mu_{A'}(x) = 1 - \mu_A(x)$$

Relacja	Stwierdzenie x jest A'	Wniosek y jest B'
1	A	B
2a	Bardzo A	Bardzo B
2b	Bardzo A	B
3a	Mniej więcej A	Mniej więcej B
3b	Mniej więcej A	B
4a	Nie A	Nieokreślone
4b	Nie A	Nie B

Modus tollens [2]

Relacja	Przesłanka y jest B'	Wniosek x jest A'
1	Nie B	Nie A
2	Nie bardzo B	Bardzo A
3	Mniej więcej B	Mniej więcej A
4a	B	Nieokreślone
4b	B	A

Sterownik Mamdaniego

$$\mu_{A \rightarrow B}(x, y) = T(\mu_A(x), \mu_B(x))$$

- Reguła minimum – suma mnogościowa
- Reguła typu iloczyn (Larsena) – iloczyn algebraiczny

Reguły rozmytych implikacji

Niech A i B będą zbiorami rozmytymi, $A \subseteq X$ oraz $B \subseteq Y$.

Rozmytą implikacją $A \rightarrow B$ nazywamy relację R określoną w $X \times Y$ i zdefiniowaną za pomocą jednej z poniższych reguł.

1. Reguła typu minimum, tzw. reguła Mamdaniego:

$$\mu_{A \rightarrow B}(x, y) = \mu_R(x, y) = \min[\mu_A(x), \mu_B(y)]$$

2. Reguła typu iloczyn, tzw. reguła Larsena:

$$\mu_{A \rightarrow B}(x, y) = \mu_R(x, y) = \mu_A(x) \cdot \mu_B(y)$$

A	B	Min(A,B)	A*B	$\mu_{A \rightarrow B}(x, y)$
0	0	0	0	1
0	1	0	0	1
1	0	0	0	0
1	1	1	1	1

Implikacje wnioskowania logicznego

- Kleene-Dienes (binarna)

$$\mu_{A \rightarrow B}(x, y) = \max(1 - \mu_A(x), \mu_B(y))$$

- Łukasiewicz

$$\mu_{A \rightarrow B}(x, y) = \min(1, 1 - \mu_A(x) + \mu_B(y))$$

- Reichenbach

$$\mu_{A \rightarrow B}(x, y) = 1 - \mu_A(x) + \mu_A(x)\mu_B(y)$$

- Fodor

$$\mu_{A \rightarrow B}(x, y) = \begin{cases} 1 & \mu_A \leq \mu_B \\ \max(1 - \mu_A(x), \mu_B(y)) & \mu_A > \mu_B \end{cases}$$

- Rescher

$$\mu_{A \rightarrow B}(x, y) = \begin{cases} 1 & \mu_A \leq \mu_B \\ 0 & \mu_A > \mu_B \end{cases}$$

- Goguen

$$\mu_{A \rightarrow B}(x, y) = \begin{cases} 1 & \mu_A = 0 \\ \min(1, \frac{\mu_B}{\mu_A}) & \mu_A > 0 \end{cases}$$

- Gödel

$$\mu_{A \rightarrow B}(x, y) = \begin{cases} 1 & \mu_A < \mu_B \\ \mu_B & \mu_A > \mu_B \end{cases}$$

Implikacje wnioskowania logicznego c.d.

- Yager

$$\mu_{A \rightarrow B}(x, y) = \begin{cases} 1 & \mu_A = 0 \\ \mu_B^{\mu_A} & \mu_A > 0 \end{cases}$$

- Zadeh

$$\mu_{A \rightarrow B}(x, y) = \max(\min(\mu_A(x), \mu_B(y)), 1 - \mu_A(x))$$

- Willmott

$$\mu_{A \rightarrow B}(x, y) = \min \left\{ \begin{array}{l} \max(1 - \mu_A(x), \mu_B(y)) \\ \max(\mu_A(x), 1 - \mu_B(y), \min(1 - \mu_A(x), \mu_B(y))) \end{array} \right\}$$

- Dubois-Prade

$$\mu_{A \rightarrow B}(x, y) = \begin{cases} 1 - \mu_A(x) & \mu_B(y) = 0 \\ \mu_B(y) & \mu_A(x) = 1 \\ 1 & \text{w przeciwnym przypadku} \end{cases}$$

Implikacje wnioskowanie logiczne

- Implikacja binarna $\mu_{A \rightarrow B}(x, y) = \max(1 - \mu_A(x), \mu_B(y))$

A	B	Max(A,B)	$\mu_{A \rightarrow B}(x, y)$
0	0	1	1
0	1	1	1
1	0	0	0
1	1	1	1

- Implikacja Łukasiewicza

$$\mu_{A \rightarrow B}(x, y) = \min(1, 1 - \mu_A(x) + \mu_B(y))$$

A	B	1-A+B	Min(.)	$\mu_{A \rightarrow B}(x, y)$
0	0	1	1	1
0	1	2	1	1
1	0	0	0	0
1	1	1	1	1

Implikacje wnioskowanie logiczne

- Implikacja Reichenbach

$$\mu_{A \rightarrow B}(x, y) = 1 - \mu_A(x) + \mu_A(x)\mu_B(y)$$

A	B	$1 - \mu_A(x) + \mu_A(x)\mu_B(y)$	$\mu_{A \rightarrow B}(x, y)$
0	0	1	1
0	1	1	1
1	0	0	0
1	1	1	1

- Implikacja Fodor

$$\mu_{A \rightarrow B}(x, y) = \begin{cases} 1 & \mu_A \leq \mu_B \\ \max(1 - \mu_A(x), \mu_B(y)) & \mu_A > \mu_B \end{cases}$$

A	B		$\mu_{A \rightarrow B}(x, y)$
0	0	1	1
0	1	1	1
1	0	0	0
1	1	1	1

Zastosowania

- rozpoznawanie obrazów, przetwarzanie obrazów, diagnostyka techniczna, analiza uszkodzeń, komputerowe wspomaganie decyzji, sterowanie złożonymi procesami
- sterowanie ciśnieniem pary w kotłach i szybkością silnika parowego Mamdani 1974
- sterowanie procesem grzewczym wody Lemke i Kikert 1976
- sterowanie ruchem ulicznym Pappis i Mamdani 1977
- autopilot statków ze wspomaganie systemu rozmytego van Amerongen Lemke van der Veen 1977
- instalacja przemysłowa pieców obrotowych w cementowni Larsen 1980
- Matsushita Electrical - pralki automatyczne (lata 1980) - wykorzystanie sensorów, zależność długości prania oraz ilości detergentów od wielkości ładunku (ciężaru) i od stopnia zabrudzenia mierzonej sensorami
- Matsushita Electrical - odkurzacz - stopień ssania od stopnia zabrudzenia odkurzonej powierzchni

Zastosowania

- Mitsubishi Heavy Industry - system klimatyzacji pomieszczeń - obniżenie zużycia energii o 24% w stos. do standardowej proc. klimatyzacji
- Sanyo Fisher - kamera 8 mm z automatyką ogniskowania i określania warunków oświetlenia
- Matsushita - elektroniczny stabilizator obrazu
- Sugeno - model helikoptera bezzałogowego (lata 90-te) - reagującego na rozmyte rozkazy przekazywane drogą radiową
- automatyczne przekładnie biegów, układów blokowania hamulcach
- wspomaganie diagnostyki medycznej, w lingwistyce i ekonomii...

