

Sieci neuronowe


# Sieć Kohonena

dr inż. Tomasz Piłot

# Literatura

1. Tadeusiewicz R.: **Sieci neuronowe**. Akademicka Oficyna Wydawnicza, Warszawa 1993
2. Osowski S.: **Sieci neuronowe w ujęciu algorytmicznym**. WNT, Warszawa 1996
3. Hertz J., Krogh A., Palmer R. G.: **Wstęp do teorii obliczeń neuronowych**. WNT, Warszawa 1993
4. Masters T.: **Sieci neuronowe w praktyce. Programowanie w C++**. WNT, Warszawa 1996
5. **Zastosowania sztucznej inteligencji w inżynierii produkcji**. Pod Red. R. Knosali, WNT 2002
6. Larose D.T.: **Odkrywanie wiedzy z danych**. PWN, 2006

# Schemat wyjściowej warstwy sieci o algorytmie uczenia o konkurencji ostrej



[wektor cech wejściowych  $x_j$ ]

# Zastosowania

- Kodowanie i kompresja danych
- Aproksymacja funkcji
- Przetwarzanie obrazów
- Inicjalizacja parametrów uczenia innych sieci
- Analiza statystyczna
- ...

# Efekty działania sieci o algorytmie WTA

- Wyznaczanie kategorii (grupy) na podstawie korelacji w danych wejściowych (zbiorze uczącym),
- Związywanie kategorii z pojedynczym neuronem zwycięskim (kwantowanie wektorowe) – wektor wejściowy (przykład uczący) jest reprezentowany przez indeks neuronu zwycięskiego,

# Wady działania sieci o algorytmie WTA

- Jedna komórka reprezentuje jedną kategorię, czyli liczba rozpoznawanych kategorii wynosi  $N$  ( $N$  – liczba neuronów),
- Nie jest odporna na uszkodzenia – utrata danego neuronu oznacza utratę kategorii
- Nie może reprezentować wiedzy wielopoziomowej. Nie ma kategorii wewnątrz kategorii.

# Algorytm uczenia Kohonena

## Metoda uczenia konkurencyjnego

Modyfikacja wag połączeń sieci:

$$w_{i*j} = w_{i*j} + \eta(t) (x_j^\mu - w_{i*j}),$$

gdzie:  $\eta(t)$  – współczynnik uczenia,  $t$  – numer iteracji,  $x_j^\mu$  – wartość  $j$ -tej cechy  $\mu$ -tego wzorca wejściowego,  $w_{ij}$  – wartość wagowa połączenia wejściowego węzła  $j$  z  $i$ -tym neuronem wyjściowym.

Wartość wyjściowa:

$$h_i^\mu = \sum_j w_{ij} x_j^\mu = \mathbf{w}_i \cdot \mathbf{x}^\mu$$

Przy normalizacji wektora wag oraz normalizacji wektorów wejściowych spełniona jest zależność:

$$|\mathbf{w}_{i*} - \mathbf{x}^\mu| \leq \mathbf{w}_i \cdot \mathbf{x}^\mu$$

Dla innych miar:

$$d(\mathbf{x}^\mu, \mathbf{w}_{i*}) = \min d(\mathbf{x}, \mathbf{w}_i), \quad 0 \leq i \leq n$$

## Normalizacja wektora wejściowego i wagowego

Sposoby normalizacji można przedstawić następująco:

- redefinicja składowych wektora wejściowego:

$$x_j \leftarrow \frac{x_j}{\sqrt{\sum_{j=1}^N x_j^2}}$$


- zwiększenie wymiaru przestrzeni wejściowej o jeden, tzn. z  $R^N \rightarrow R^{N+1}$ , gdzie:

$$\sum_{j=1}^{N+1} x_j^2 = 1$$



# Algorytm uczenia konkurencyjnego WTA

dostosowanie wektorów wag neuronów zwyciężskich do reprezentacji grup wzorców wejściowych



# Algorytm uczenia Kohonena

## Funkcja celu

$$E\{\mathbf{w}_{ij}\} = \frac{1}{2} \sum_{ijk} M_i^\mu (\mathbf{x}_j - \mathbf{w}_{ij})^2 = \frac{1}{2} \sum_{\mu} |\mathbf{x}^\mu - \mathbf{w}_{i^*}|$$

$$M_i^\mu = \begin{cases} 1 & \text{jeżeli } i = i^*_\mu \\ 0 & \end{cases}$$

$$\langle \Delta \mathbf{w}_{ij} \rangle = -\eta \frac{\partial E}{\partial \mathbf{w}_{ij}} = \eta \sum_{\mu} M_i^\mu (\mathbf{x}_j - \mathbf{w}_{ij})$$

## Problem zmęczenia neuronów - zapobieganie

- podstawienie jako początkowego wektora wag  $\mathbf{w}_i^0$  równego samemu wektorowi wejściowemu,
- aktualizację wag wszystkich tego typu neuronów tak jak zwycięzców, przy zmniejszonym współczynniku uczenia  $\eta_i(t)$ , tzw. nieszczelne uczenie się,
- aktualizację wag sąsiednich neuronów jako zwycięskich (odwzorowanie cech istotnych),
- dodanie szumu do wektorów wejściowych, dzięki czemu otrzymuje się tzw. rozmyte wektory,
- stopniowe włączanie w proces uczenia wzorców wejściowych [\[1\]](#).

Algorytm uczenia Kohonena

# Funkcja celu Rittera i Schultena

$$E\{\mathbf{w}_{ij}\} = \frac{1}{2} \sum_{ijk} M_i^\mu \Lambda(i, k) (\mathbf{x}_j - \mathbf{w}_{ij})^2 = \frac{1}{2} \sum_{\mu} \Lambda(i, i^*) \|\mathbf{x}^\mu - \mathbf{w}_{i^*}\|$$

# Metoda uczenia konkurencyjnego z funkcją sąsiedztwa

Modyfikacja wartości wag połączeń sieci:

$$w_{ij}(t) = w_{ij}(t-1) + \eta(t) \Lambda(i, i^*) (x_j - w_{ij}(t-1))$$

Określenie węzła o maksymalnej wartości wyjściowej, gdy  $|\mathbf{w}_i| = 1$  :

$$|\mathbf{w}_{i^*} - \mathbf{x}^\mu| \leq \mathbf{w}_i \cdot \mathbf{x}^\mu$$

Obliczenie wartości funkcji sąsiedztwa w otoczeniu węzła zwycięskiego  $i^*$ :

$$\Lambda(i, i^*) = \exp\left(-\frac{d^2(i, i^*)}{2\lambda(t)^2}\right)$$

Obliczenie nowych wartości funkcji promienia sąsiedztwa  $\lambda(t)$  i współczynnika uczenia  $\eta(t)$ .

# Algorytm uczenia Kohonena

## Funkcje sąsiedztwa

- typu prostokąta:

$$\Lambda(i, i^*) = \begin{cases} 1 & \text{dla } d(i, w) \leq \lambda(t) \\ 0 & \text{dla innych} \end{cases}$$

- typu Gaussa:

$$\Lambda(i, i^*) = \exp\left(-\frac{d^2(i, i^*)}{2\lambda(t)^2}\right),$$

gdzie:

$\lambda(t)$  - promień sąsiedztwa o wartości malejącej wraz z czasem uczenia  $t$ ,


$d(i, i^*)$  - odległość w mierze Euklidesa węzła zwycięskiego  $i^*$  i  $i$ -tego w przestrzeni wyjściowej sieci.

- typu „Mexican hat” (kapelusz meksykański), w którym realizowana jest zasada hamowania obocznego, czyli ujemnego wpływu na węzły najdalej położone w stosunku do węzła zwycięskiego:


$$\Lambda(i, i^*) = \frac{1 - s(t)d_{ii^*}^2}{(1 + d_{ii^*}^2)^2} \quad d_{ii^*} = |r_i - r_{i^*}| \quad s(t) = \tanh\left(\frac{t}{T_{11}}\right)$$

# Funkcje sąsiedztwa

(a)



(b)



# Algorytm uczenia Kohonena

## Funkcje promienia sąsiedztwa

Jako funkcje promienia sąsiedztwa  $\lambda(t)$  stosuje się zwykle następujące:

- funkcję liniową  $\lambda_1(t)$ :

$$\lambda_1(t) = \lambda_0 \left( 1 - \frac{t}{T_1} \right) + 1$$

gdzie:  $T_1$  określa maksymalny okres,  
 $t$  określa numer iteracji,  
 $\lambda_0$  wartość początkowa promienia sąsiedztwa.

- funkcję wykładniczą:

$$\lambda_2(t) = \lambda_0 \left( \frac{\lambda_{\min}}{\lambda_0} \right)^{\frac{t}{T_{\max}}}$$

gdzie:  $T_{\max}$  - parametr określający maksymalną wartość iteracji,  
 $\lambda_{\min}$  - wartość przejściowa promienia sąsiedztwa, przy którym funkcja ta przechodzi przez punkt o współrzędnych  $(T_{\max}, \lambda_{\min})$ .



Algorytm uczenia Kohonena

# Funkcje współczynnika uczenia

Funkcja liniowa

$$\eta(t) = \eta_0 \left( 1 - \frac{t}{T_1} \right)$$

Funkcja potęgowa

$$\eta(t) = \eta_0 \alpha t^{-\alpha}$$

Funkcja wykładnicza

$$\eta_2(t) = \eta_0 \left( \frac{\eta_{\min}}{\eta_0} \right)^{\frac{t}{T_{\max}}}$$

# Funkcje współczynnika uczenia sieci $\eta(t)$ c.d.

Funkcja pulsacyjna [1]:

$$\eta_3(t) = \eta_0 \left| e^{-at} \cos(b(t) t) \right|$$

gdzie:

$$b(t) = \frac{\pi}{2T_z} K(t)$$


$$a(t) = W b(t)$$

gdzie  $T_z$  jest numerem epoki dla pierwszego miejsca zerowego funkcji  $\eta_3$ ,  
 $W$  jest współczynnikiem wielkości spadku wartości funkcji  $\eta_3$ .

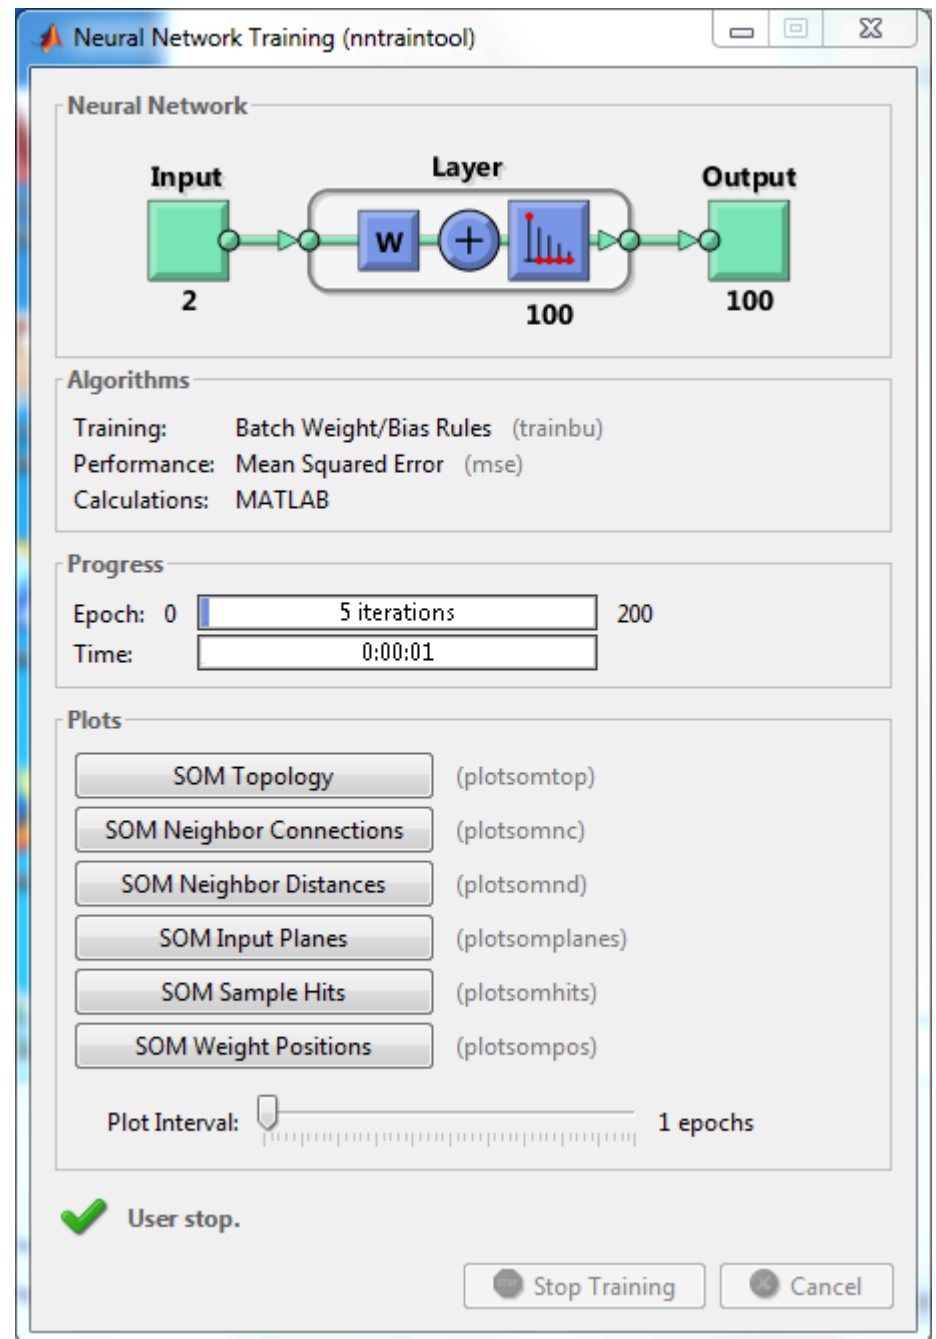
Natomiast  $K(t)$  określa położenie drugiego miejsca zerowego funkcji  $\eta_3$ :

$$K(t) = e^{\left( \frac{t-T_z}{T_z Nk} \right)}$$

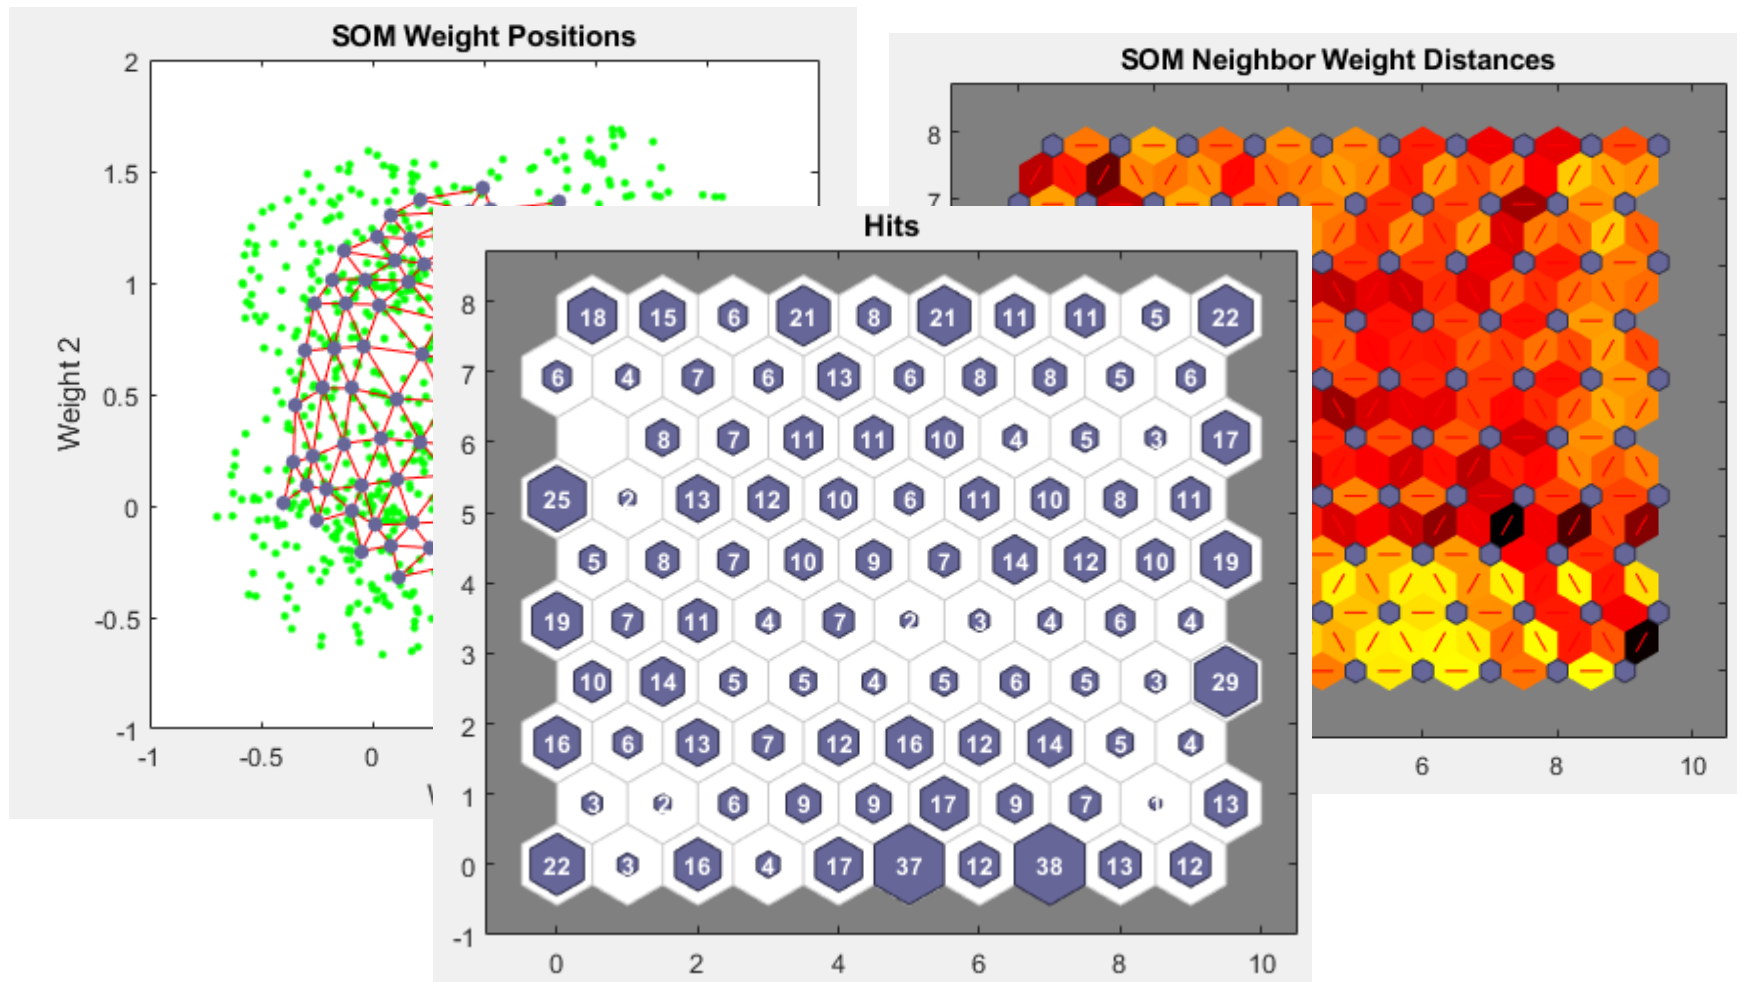
# Porównanie funkcji współczynnika uczenia



# Przykład grupowania




# Po 5 iteracjach




# Pozycje neuronów w trakcie uczenia – 5 iteracji



# Pozycje neuronów w trakcie uczenia – 32 iteracja




# Pozycje neuronów w trakcie uczenia – 63 iteracja


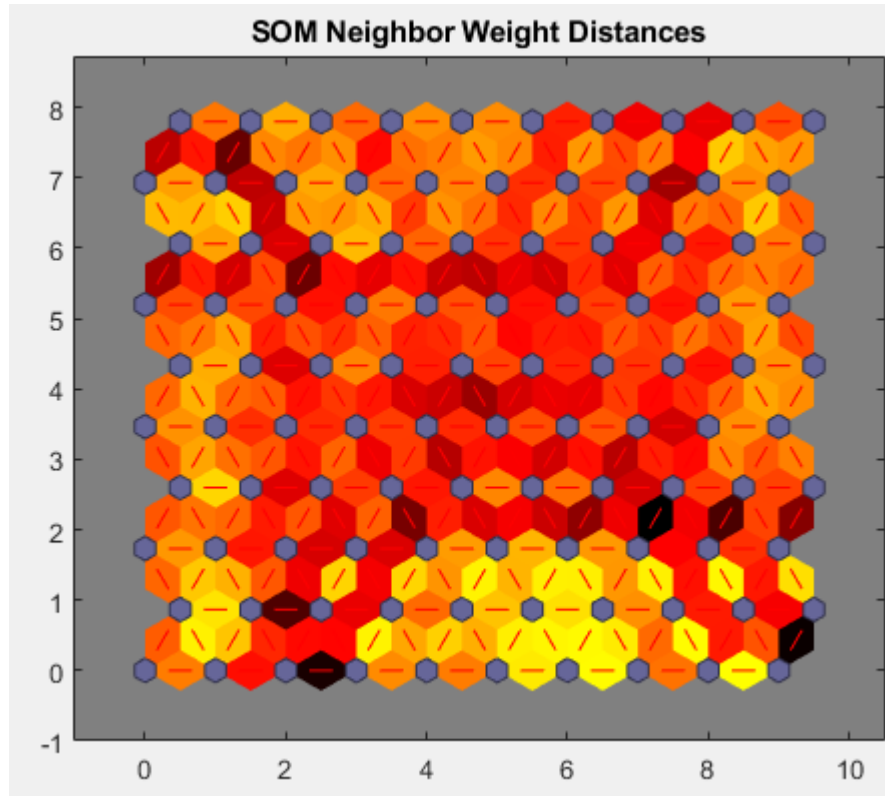





# Pozycje neuronów w trakcie uczenia – 200 iteracja



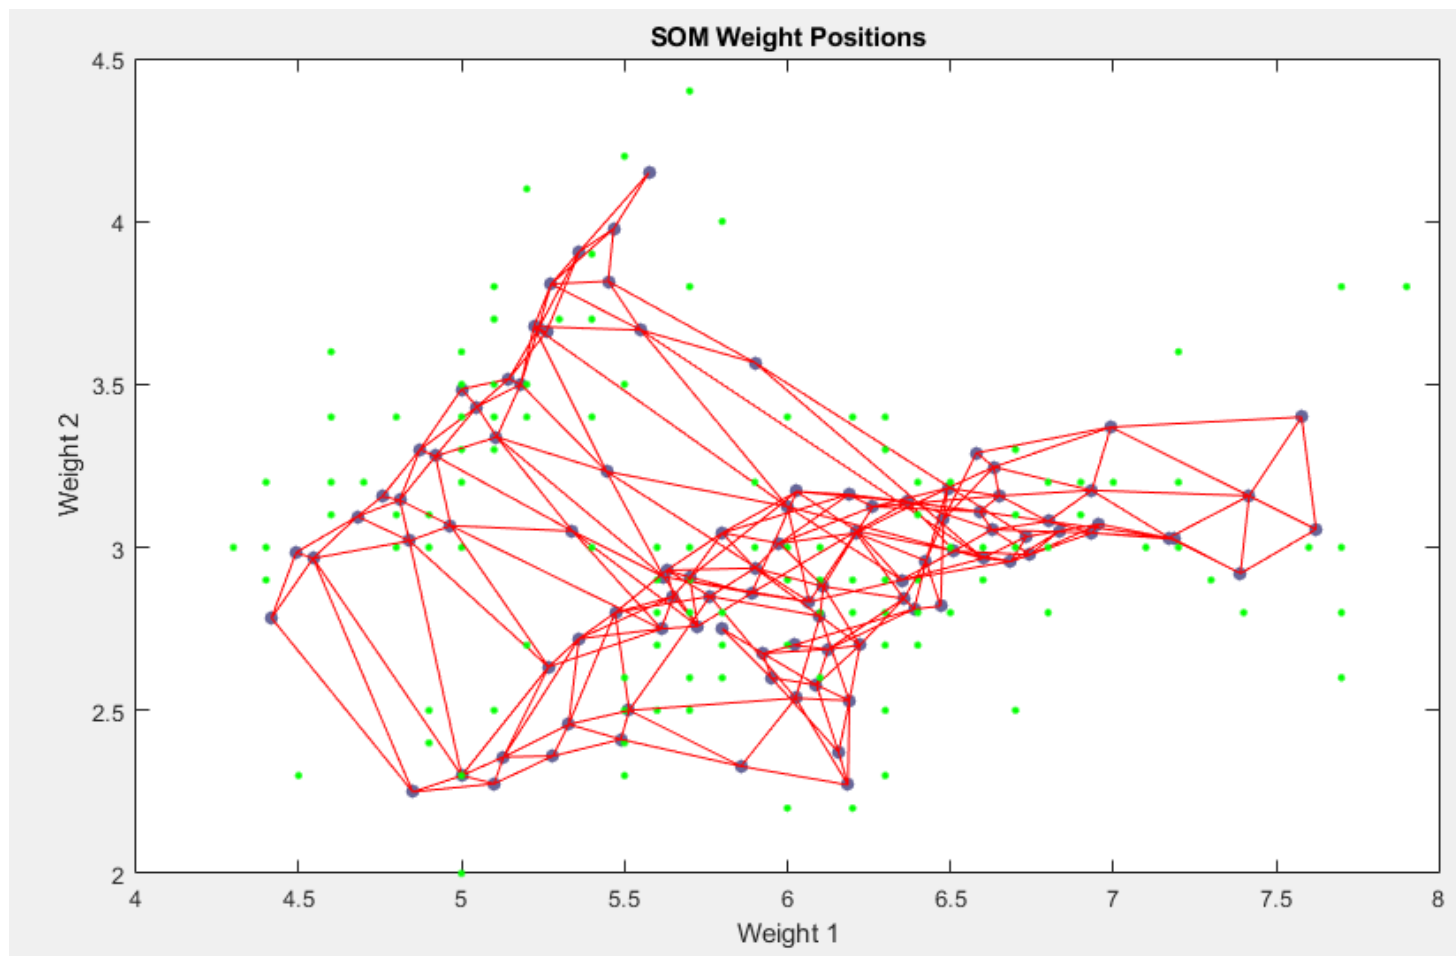
# Odległości między neuronami




# Przykład iris – stan początkowy




# Przykład iris




# Przykład iris



# Przykład iris



# Iris – aktywność neuronów



# Algorytm „gazu neuronowego” cz.I

1. Sortowanie węzłów wyjściowych ze względu na odległość wzorca wejściowego, w mierze Euklidesa, od macierzy wag, związanej z danym węzłem:

$$d_0 < d_1 < \dots < d_{n-1}$$

gdzie:

$n$  – liczba neuronów wyjściowych,

$m=0,1,\dots,n-1$  – określa pozycję węzła  $i$ -tego w wektorze odległości,

$d_m$  – oznacza odległość na  $m$ -tej pozycji  $i$ -tego węzła wyjściowego w uporządkowanym wektorze odległości, która wyraża się zależnością:

$$d_m = |\mathbf{x} - \mathbf{w}_i|$$

gdzie:

$\mathbf{x}$  - macierz wzorca wejściowego,

$\mathbf{w}_i$  - macierz wag połączeń  $i$ -tego węzła wyjściowego  
i macierzy wejściowej  $\mathbf{x}$ .



# Algorytm „gazu neuronowego” cz.II

2. Określenie wartości funkcji sąsiedztwa na węzłach uporządkowanych wg odległości  $d_m$ :

$$\Lambda(i, i^*) = e^{\frac{\lambda(t)}{d_m^2}}$$

gdzie  $\lambda(t)$  jest funkcją promienia sąsiedztwa.

Funkcja celu stowarzyszona z funkcją sąsiedztwa charakteryzuje się, przy wartościach  $\lambda \rightarrow 0$ , przejściem w algorytm uczenia konkurencji ostrej. Postać funkcji przybiera kształt paraboli. W przypadku jednak, gdy  $\lambda \rightarrow \infty$ , wtedy przy wolnej zmianie  $\lambda$  dostajemy funkcję wielomodalną, o wielu minimach lokalnych. W tym momencie funkcja ta zapewnia dojście procesu uczenia do globalnego minimum. Wskutek tego algorytm ten jest określany jako najbardziej skuteczny wśród takich algorytmów jak mapa Kohonena czy k-means [3,6].

# Dendrogram podobieństwa geometrycznego <sup>1</sup>

I: geo, Euklidesa

