

KRZYSZTOF MICHALIK

PREDYKTOR 4.0

dla Windows 9x/NT/2000

**SYSTEM DO BUDOWY STATYCZNYCH I DYNAMICZNYCH MODELI
PROGNOSTYCZNYCH**

PODRĘCZNIK UŻYTKOWNIKA



Artificial Intelligence Laboratory

ul. Kossutha 7, 40-844 KATOWICE
tel./fax: tel.: (0-32) 254-41-01 w. 374
tel. kom. 0 502-99-27-28
e-mail: aitech@aitech.com.pl
WWW: <http://www.aitech.com.pl>

Copyright ©1990-2003 AITECH & Krzysztof Michalik

AITECH, Sphinx, CAKE oraz **Neuronix**
są prawnie zastrzeżonymi znakami towarowymi firmy
AITECH, ARTIFICIAL INTELLIGENCE LABORATORY

Spis treści

Rozdział 1. Czym jest system Predyktor ?	1
Użytkownicy systemu Predyktor	3
Zastosowania systemu Predyktor	3
Zestawienie metod i trybów pracy systemu Predyktor	5
Rozdział 2. Menu systemu Predyktor	1
Grupa Plik	3
Grupa Edycja	4
Grupa Widok	4
Grupa Narzędzia	5
Grupa Pomoc	8
Użycie modelu	9
Arkusze kalkulacyjne i gromadzenie danych	9
Przygotowanie danych do budowy modelu	10
Rozdział 3. Wstęp do analizy statystycznej	1
Rozkład prawdopodobieństwa	3
Opis statystyczny ciągu czasowego	4
Interpretacja wybranych miar	5
Analiza statystyczna w systemie Predyktor	6
Rozdział 4. Metody budowy modeli w systemie Predyktor	1
Jak powstaje model ?	3
Modele ciągów czasowych	3
Modele pełne (obiektów)	4
Procedura budowy modelu	4
Realizacja wybranych metod w systemie Predyktor	5
Modele nieparametryczne ciągów czasowych	7
Modele liniowe i nieliniowe - porównanie	7
Rozdział 5. Przykłady prognoz	1
Charakterystyka trybów pracy	3
Tryb prognoz jednoseryjnych dla modeli ciągów czasowych	3
Tryb prognoz jednoseryjnych dla modeli pełnych	11
Tryb prognoz wieloseryjnych dla modeli ciągów czasowych	12
Rozdział 6. Obsługa systemu Predyktor	1
Dostępne opcje w systemie Predyktor	3
Utworzenie nowego modelu	4
Menadżer modeli prognostycznych	4
Dialog właściwości modelu	5
Generowanie raportów	6
Analiza przy pomocy transformacji Fouriera	7
Rozdział 7. Analiza sygnałów w dziedzinie częstotliwości	1
Podstawowe informacje praktyczne	3
Podstawowe informacje praktyczne	4
Rozdział 8. Informacje uzupełniające	1
Podstawowe klasyfikacje modeli	3
Koncepcja modelu autoregresji	3
Na czym polega metoda najmniejszych kwadratów	4
Identyfikacja modeli ciągów czasowych i modeli obiektów (zjawisk)	5
Identyfikacja przebiegu sinusoidalnego	6
Błędy prognozy	8
Rozdział 9. Literatura	9

Czym jest system Predyktor ?

W rozdziale:

- Użytkownicy systemu Predyktor
- Co umożliwia system Predyktor Użytkownikowi?
- Inne możliwości systemu Predyktor
- Zastosowania systemu Predyktor
- Zestawienie metod i trybów pracy systemu Predyktor

Czym jest system Predyktor ?

System Predyktor jest narzędziem służącym do budowy modeli ciągów czasowych oraz obiektów. System jest niezależny dziedzinowo i może zostać wykorzystany zarówno do budowy modeli ekonomicznych jak również technicznych. System posiada szczególnie rozbudowaną część analizy danych pod kątem budowy modeli ciągów czasowych. Jednym z podstawowych zastosowań modeli ciągów czasowych jest wykonywanie w oparciu o nie prognoz krótko i długoterminowych. Podczas budowy modeli procesów i obiektów może wystąpić problem nieliniowości obiektu (zjawiska) powodujący nieliniowość generowanych danych. Tradycyjne modele ciągów czasowych i obiektów są najczęściej liniowe, co powoduje rozbieżne od oczekiwanych rezultaty identyfikacji modelu ciągu czasowego lub obiektu w postaci niezgodności pomiędzy danymi generowanymi przez model, a danymi empirycznymi. Rozwiązaniem tych problemów są nieliniowe modele ciągów czasowych i obiektów budowane klasycznymi metodami, najczęściej złożone obliczeniowo i z trudną do ustalenia strukturą. Wykorzystując osiągnięcia sztucznej inteligencji możliwe jest zbudowanie modelu nieliniowego przy pomocy sztucznej sieci neuronowej. Model w postaci sztucznej sieci neuronowej może być zarówno modelem ciągu czasowego jak również modelem obiektu o nadzwyczaj dobrych własnościach w zakresie modelowania nieliniowości.

UŻYTKOWNICY SYSTEMU PREDYKTOR

System Predyktor może być wykorzystywany przez:

1. Menadżerów zarządzających przedsiębiorstwami w zakresie:

- taktycznego i strategicznego planowania finansowego,
- zarządzania finansami przedsiębiorstw,
- podejmowania decyzji strategicznych i operacyjnych,
- prognoz strategicznych i operacyjnych,
- badań operacyjnych

2. Biura maklerskie w zakresie:

- tworzenia modeli wybranych procesów socjologicznych na rynkach finansowych,
- tworzenia modeli wyceny instrumentów rynku kapitałowego,
- typowej prognozy krótko i długoterminowej dla instrumentów rynku kapitałowego.

3. Otwarte i zamknięte fundusze inwestycyjne i emerytalne w zakresie:

- prognoz wskaźników finansowych i kursów,
- tworzenia modeli

4. Działy logistyki i zaopatrzenia przedsiębiorstw w zakresie:

- planowaniu zapotrzebowania na materiały w procesie produkcyjnym,

5. Wyższe uczelnie o profilach ekonomicznych, technicznych i społecznych na etapie wspomagania dydaktyki zarówno z przedmiotów dziedzinowych, jak również dotyczących zagadnień sztucznej inteligencji.

ZASTOSOWANIA SYSTEMU PREDYKTOR

Potrzeba prognozowania występuje w każdej dziedzinie nauki i powinna być częścią niektórych decyzji badawczych. Dla przykładu stacja sanitarno-epidemiologiczna potrzebuje prognoz dotyczących możliwości rozprzestrzenienia się choroby zakaźnej. Podobnych informacji potrzebują strategiczne agendy rządowe celem przygotowania odpowiedniego zabezpieczenia medycznego. Potrzeba prognozowania występuje również w każdym przedsiębiorstwie i powinna być częścią decyzji menedżerskich na poziomie zarządu oraz decyzji technicznych podejmowanych przez kadrę inżynierską w sprawach np. eksploatacji obiektów.

Dla przykładu dział marketingu potrzebuje prognoz dotyczących popytu i podaży, według segmentów rynku i kategorii wyrobów oraz wrażliwości popytu na zmiany niektórych czynników np. cen. Podobnych informacji potrzebuje dział przygotowania produkcji do sporządzenia planów wielkości i struktury produkcji. Rachunkowość jest zainteresowana przewidywaniem kosztów, natomiast działy finansowe przygotowaniem prognoz obejmujących przychody i wydatki, płynność finansową. Jednostki utrzymania ruchu są zainteresowane prognozami dotyczącymi żywotności eksploatowanych obiektów oraz bieżącego zapotrzebowania na poszczególne media niezbędne w ich pracy.

W każdym systemie jakim jest również przedsiębiorstwo zachodzą pewne relacje przekształcające wejście tego systemu na wyjście $X \rightarrow Y$. Zależności opisujące takie przekształcenie są prawie zawsze nieliniowe, oznacza to że tradycyjne liniowe ekonometryczne metody budowy modeli są niewystarczające. Do podstawowych ich wad należy duża złożoność obliczeniowa oraz brak metod, które pozwalają modelować systemy nieliniowe o nieznanym kształcie.


Sieć neuronowa jest nieliniowa już w swojej naturze, dlatego pozwala na bardzo dokładne aproksymowanie (możliwa jest również interpolacja) danych empirycznych, co odpowiada rezultatom uzyskanym dla bardzo wyszukanych nieliniowych metod statystycznych.

Sieci neuronowe okazały się skutecznym narzędziem prognozowania w wielu dziedzinach. Często rezultaty ich prognoz okazują się lepsze od klasycznych metod statystycznych. Dla przykładu: Dutta i Shekhar podają, że w odniesieniu do wyceny klasyfikacyjnej papierów wartościowych (ang. bond-rating) uzyskali metodą sieci neuronowej BPN na zbiorze testowym rezultat 92.4%, w porównaniu z dokładnością 66.7% uzyskaną metodą regresji wielorakiej. Haefke i Helmenstein informują o przewadze prognozy wskaźników ATX (Austrian Traded Index) i indeksu IPOX (Initial Public Offerings) opartej o sieć neuronową w stosunku do klasycznego modelu liniowego. Prognozowanie exchange rate (za Refenes) oparte na sieci dało w ciągu 60 dni 1989 roku przynajmniej 22% zysku. Jego system raczej prognozował następną wartość w szeregu a nie punkty zwrotne (ang. turning points). W kolejnym artykule Refenes opisuje ten sam przypadek po dodaniu elementów ukrytych na tych samych danych osiągnął rezultat 25%. Z wykorzystaniem tych samych warunków, tradycyjne metody prognozowania statystycznego dały następujące wyniki: wyrównywanie wykładnicze nie dało żadnych użytecznych rezultatów natomiast autoregresja dała wynik 9%.

Typowymi problemami elektroenergetyki jest dopasowanie struktury popytu i podaży energii elektrycznej i ciepłej. Dokładne określenie popytu zarówno dla systemu lokalnego (na poziomie elektrowni) i globalnego (na poziomie sieci przesyłowej) pozwala na wymierne oszczędności. Stosowane obecnie systemy wykorzystują głównie liniowe metody predykcji dobrze znane ze statystyki. Metody takie sprawdzają się, jeżeli rzeczywiste procesy zachodzące w systemach elektroenergetycznych nie są silnie nieliniowe.

Przeprowadzone badania naukowe i udane wdrożenia na całym świecie dowodzą, że sieci neuronowe wykazują dużo większą zdolność adaptacji do wymagań stawianych przez nowoczesne metody analizy danych. Należy podkreślić, że jest możliwe optymalizowanie wskaźników prognoz w stosunku do metod modelowania statystycznego o wielkości rzędu od 10% do 30%. W ten sposób, jeżeli uzyskana prognoza metodą statystyczną charakteryzuje się wskaźnikiem sprawdzalności w realnym systemie elektroenergetycznym rzędu 60%-70%, to jest możliwe podwyższenie tego wskaźnika do granicy 90%. Co pozwala już w pełni kontrolować popyt i podaż na energię. Za pomocą systemu Neuronix można budować modele zarówno przyczynowo-skutkowe składające się z kilkudziesięciu wybranych zmiennych wejściowych, jak również modele ciągów czasowych w których posiadamy tylko ciąg wartości opisujących dany proces i nie wiemy dokładnie co jest jego przyczyną. W literaturze znajdują się inspirujące przykłady zastosowań sieci neuronowych. Stanisław Osowski podaje w książce „Sieci neuronowe w ujęciu algorytmicznym” informacje dotyczące predykcji obciążenia sieci w polskim systemie energetycznym. Autorowi udało się zmniejszyć **błąd predykcji** do wartości 1% w porównaniu z 2% dla predykcji za pomocą modelu statystycznego. Literatura podaje również przykłady użycia sieci w diagnostyce obiektów energetycznych. Korbicz, Obuchowicz, Uciński przedstawiają „Diagnostyczny układ neuronowy dla symulatora elektrowni ciepłej”. Układ pozwala po odpowiednim wyuczeniu sieci sygnalizować problemy występujące podczas eksploatacji turbiny.

W zakresie emisji zanieczyszczeń jest możliwe prognozowanie stężenia poziomu zanieczyszczenia atmosfery za pomocą zarówno modelu przyczynowo-skutkowego jak również w postaci szeregu czasowego. Efekty takiej prognozy mogą być bardzo użyteczne dla przedsiębiorstwa energetycznego ze względu na konieczność spełniania określonych norm szkodowości względem środowiska naturalnego.



Rys. 1. Przykładowa prognoza stężenia zanieczyszczeń

ZESTAWIENIE METOD I TRYBÓW PRACY SYSTEMU PREDYKTOR

		Tryb pracy dla pojedynczych ciągów czasowych	Tryb pracy dla modeli obiektów (regresja wielowymiarowa, wieloraka)	Tryb pracy dla łącznej identyfikacji wielu ciągów czasowych
Modele ciągów	Ciąg źródłowy	+		+
	Model regresji liniowej i nieliniowej	+		+
	Model autoregresji	+		+
	Model autoregresji nieliniowej (sieć neuronowa)	+		+
Modele obiektów	Ciąg źródłowy		+	
	Model regresji wielowymiarowej		+	
	Model nieliniowej regresji wielowymiarowej (sieć neuronowa)		+	
Preprocessing danych	Filtracja i obcinanie wartości skrajanych	+	+	+
	Funkcja autokorelacji	+		+
	Funkcja autokorelacji cząstkowej	+		+
	Analiza sygnału w dziedzinie częstotliwości - transformata Fouriera	+	+	+
	Histogram o zmiennej liczbie przedziałów	+	+	+
	Średnia, odchylenie, odchylenie standardowe, wariancja, skośność (spłaszczenie), kurtoza	+	+	+
Generator ciągów czasowych	Szum o rozkładzie gaussowskim	+		+
	Szum o rozkładzie równomiernym	+		+
	Składowa deterministyczna o postaci funkcji sinus, generowana dla zadanej częstotliwości próbkowania i częstotliwości roboczej	+		+

Tryby pracy

- Tryb pracy dla pojedynczych ciągów czasowych – w tym trybie można budować modele autoregresyjne oparte o jednowymiarowy ciąg danych wejściowych
- Tryb pracy dla modeli obiektów (regresja wielowymiarowa, wieloraka) – w tym trybie można budować model o wielu wejściach oraz jednym wyjściu (tzw. modele MISO - ang. Multi Input Single Output)
- Tryb pracy dla łącznej identyfikacji wielu ciągów czasowych – w tym trybie można budować modele analogicznie jak w trybie (a) z tą różnicą że jednocześnie analizowanych jest kilkadziesiąt ciągów czasowych

Informacje uzupełniające

Maksymalna długość ciągu czasowego limitowana jest liczbą wierszy w arkuszu i wynosi 16384 komórek (liczb rzeczywistych). Maksymalna liczba ciągów czasowych limitowana jest liczbą kolumn w arkuszu i wynosi 256.

Menu systemu Predyktor

W rozdziale:

- Grupa Plik
- Grupa Edycja
- Grupa Widok
- Grupa Narzędzia
- Grupa Pomoc
- Użycie modelu
- Arkusze kalkulacyjne i gromadzenie danych
- Przygotowanie danych do budowy modelu


Menu systemu Predyktor

GRUPA PLIK

Grupa **Plik** pozwala na obsługę plików w których są przechowywane dane niezbędne dla prawidłowej pracy systemu Predyktor. Ponadto zawiera opcje służące drukowaniu zawartości arkuszy i wykresów. Podstawowymi opcjami są **Nowy Projekt** oraz **Otwórz Projekt**, które pozwalają na utworzenie nowego projektu lub wczytanie z dysku już istniejącego. Każdy projekt może zostać utworzony tylko w jednym wariancie poprzez przyjęcie określonego trybu pracy. Do wyboru są następujące tryby pracy, opisane szerzej w dalszej części instrukcji obsługi systemu Predyktor:

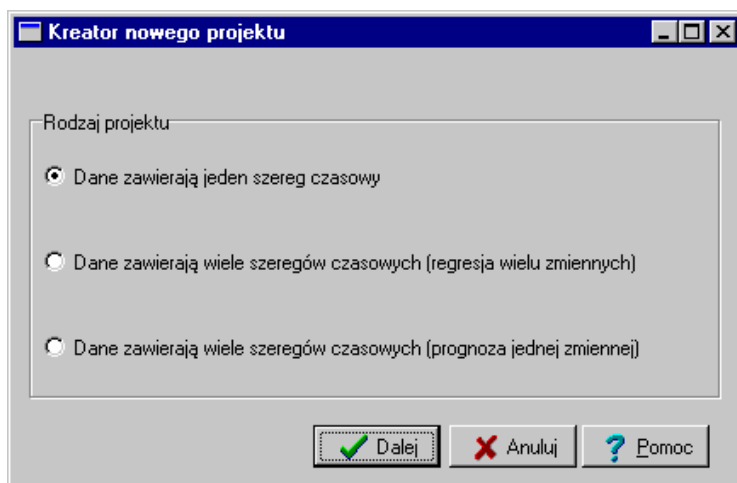
- Tryb pracy dla pojedynczych ciągów czasowych
- Tryb pracy dla modeli obiektów (regresja wielowymiarowa, wieloraka)
- Tryb pracy dla łącznej identyfikacji wielu ciągów czasowych

W ramach projektu zdefiniowane są dane wejściowe i wyjściowe niezbędne do procesu identyfikacji, parametry utworzonych modeli, dane wygenerowane w dziedzinie czasu oraz częstotliwości za pomocą tych modeli oraz typ projektu. Opcjonalnie projekt przechowuje informacje o ścieżce dostępu do projektu sieci neuronowej oraz lokalizacji systemu Neuronix, który wykorzystywany jest w zakresie modelowania nieliniowego. Rys. 2 przedstawia wygląd grupy poleceń **Plik** po uruchomieniu aplikacji Neuronix lub też po zamknięciu bieżącego projektu.

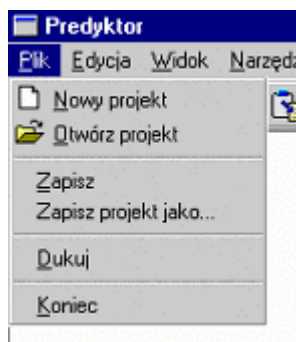


Rys. 2. Podstawowe opcje grupy **Plik**

Po utworzeniu lub wczytaniu nowego projektu Użytkownik ma dostęp do bardziej rozbudowanego menu, w skład którego wchodzi: **Zapisz**, **Zapisz jako**, **Drukuj arkusz**. Na samym dole grupy **Plik** znajdują się nazwy projektów wcześniej otwartych. Wybranie nazwy pozwala na automatyczne wczytanie już istniejącego projektu z dysku. Widok pełnej grupy **Plik** wraz z opcjami dostępnymi po otwarciu projektu pokazano na rys. 2.




Rys. 3. Dialog obsługi pliku dla nowego projektu



Rys. 4. Pełna grupa **Plik**, po wczytaniu projektu

GRUPA EDYCJA



Rys. 5. Grupa Edycja

Wytnij, Kopiuj, Wstaw


Opcja pozwala na pracę z zaznaczonymi obszarami arkusza kalkulacyjnego, poprzez ich wycinanie, kopiowanie i wstawianie w dowolny inny obszar tego samego arkusza lub innego.

GRUPA WIDOK

Grupa **Widok** umożliwia Wyświetlenie okienek dialogowych przydatnych w procesie budowy modelu.

Menedżer modeli


Menadżer modeli zawiera zestawienie (listę) modeli obiektów lub ciągów czasowych (zależnie od trybu pracy systemu). Dwukrotne kliknięcie na wybranym z listy opisie modelu umożliwia dostęp do parametrów tego modelu oraz ewentualnie dodatkowych opcji sterujących. Usuwanie modeli z listy jest możliwe przyciskiem **Usuń model**, znajdującym się w dolnej części okienka.



Rys. 6. Centralne okienko zawierające listę utworzonych modeli obiektów lub ciągów czasowych

Sterowanie obszarem wykresów

Opcja umożliwia formatowanie zakresu wyświetlanych danych wyjściowych modelu w dziedzinie czasu oraz częstotliwości. Możliwy jest sterowanie poziomym i pionowym zakresem wykresu oraz przesuwanie wykresu w kierunku poziomym i pionowym.




Rys. 7. Dialog pozwalający sterować obszarem wykresu

GRUPA NARZĘDZIA

Dodaj nowy model

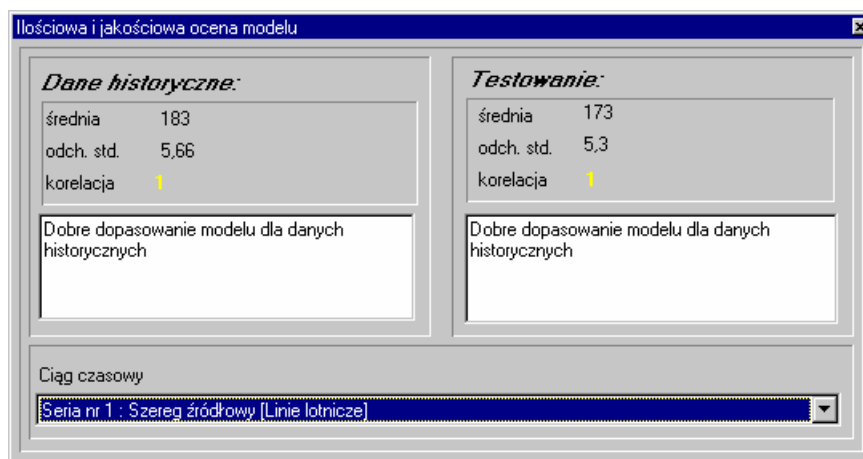
Opcja pozwala na dodanie nowego modelu do istniejącego projektu. Lista rozwijana zawiera wybór modeli dostępnych w zależności od wybranego trybu pracy



Rys. 8. Opcja umożliwiająca dodanie nowego modelu

Ilościowa i jakościowa ocena modelu

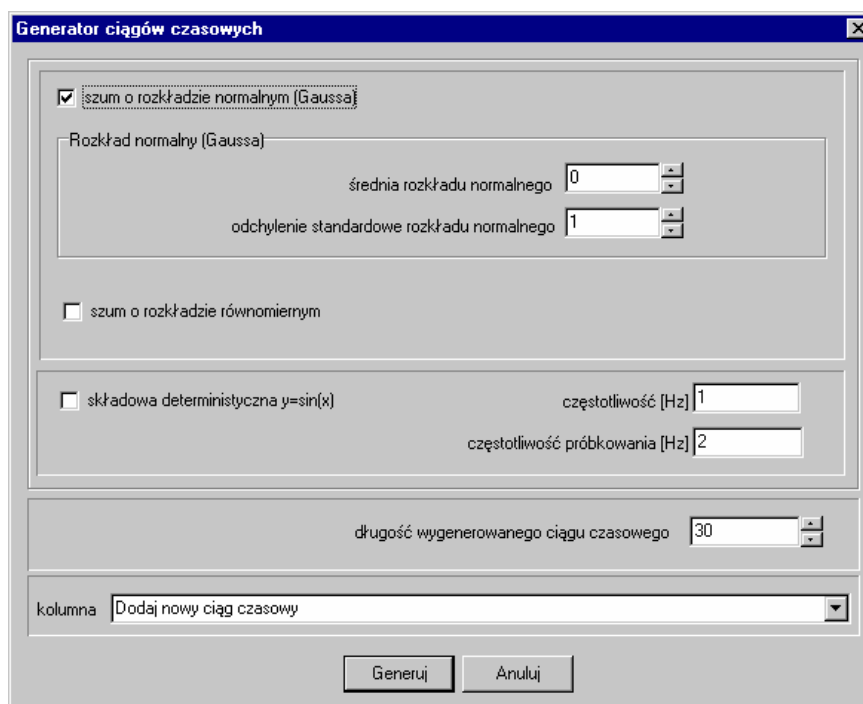
Ilościowa i jakościowa ocena modelu pozwala porównać błąd użycia modelu dla zbioru na podstawie którego identyfikowano parametry modelu obiektu lub ciągu czasowego oraz dla zbioru testowego z którego dane nie brały udziału w procesie identyfikacji. Związki ilościowe rozpatrywane są przy pomocy korelacji liniowej oraz podstawowych miar statystycznych, np. średniej, odchylenia standardowego. Jakość modelu określa komunikat werbalny wyświetlany w polu tekstowym w dolnej części dialogu.



Rys. 9. Dialog oceny ilościowej i jakościowej modelu obiektu lub ciągu czasowego

Generator ciągów czasowych

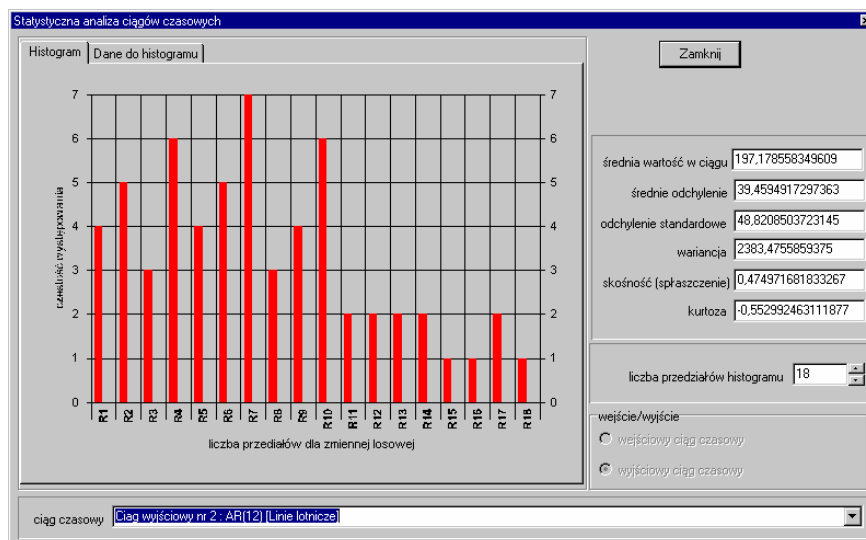
Generator ciągów czasowych służy do syntezy ciągu wartości odpowiadającego procesowi deterministycznemu w postaci funkcji sinusoidalnej oraz procesowi stochastycznemu w postaci funkcji losowej o rozkładzie równomiernym lub normalnym (Gausa). Generowanie ciągów czasowych jest możliwe w każdym trybie pracy. W trybie pracy dla wielu modeli ciągów czasowych oraz w trybie pracy dla modeli obiektów możliwy jest wybór liczby wygenerowanych ciągów oraz możliwe jest zastępowanie dowolnych ciągów czasowych wejściowych i wyjściowych ciągami generowanymi.



Rys. 10. Widok na okienko dialogu generatora ciągów czasowych

Statystyczna analiza danych wejściowych i wyjściowych


Dialog pozwala na wybór ciągu czasowego, liczby przedziałów dla histogramu oraz odczyt parametrów modelu rozkładu. Ciąg czasowy można wybrać z zakresu empirycznych danych wejściowych i wyjściowych oraz danych wyjściowych użytego modelu. W zależności od ustawionego trybu pracy opcja pracy z empirycznymi ciągami wejściowymi jest dostępna wyłącznie dla modeli obiektów. Istnieje możliwość odczytu i kopiowania liczby wartości zawierających się w poszczególnych przedziałach histogramu.




Rys. 11. Dialog obsługi statystycznej analizy danych

Selekcja zmiennych wejściowych

Dla trybu pracy z modelami obiektów (regresja wielowymiarowa) dostępna jest opcja selekcji zmiennych wejściowych. Umożliwi ona wybór zmiennych do modelu według kryteriów korelacji wzajemnej oraz ze zmienną wyjściową (objaśnianą). Wyboru zmiennych wchodzących do modelu dokonuje się poprzez zaznaczenie wybranych zmiennych znajdujących się na liście.



Rys. 12. Opcja umożliwiająca selekcję zmiennych w trybie pracy z modelami obiektów (regresji wielowymiarowej)




Rys. 13. Przykładowa selekcja zmiennych

Raport do programu MicrosoftWord

Raport pozwala w sposób syntetyczny podsumować wyniki modelowania danych empirycznych. W szczególności możliwe jest zawarcie w dokumencie programu Microsoft Word następujących informacji:

- Wykresów danych dla ciągów wyjściowych oraz ciągów referencyjnych,
- Informacji ilościowej i jakościowej o wynikach dopasowania modelu do danych empirycznych,
- Parametrów modelu.



Rys. 14. Grupa **Narzędzia**, opcja raport

GRUPA POMOC

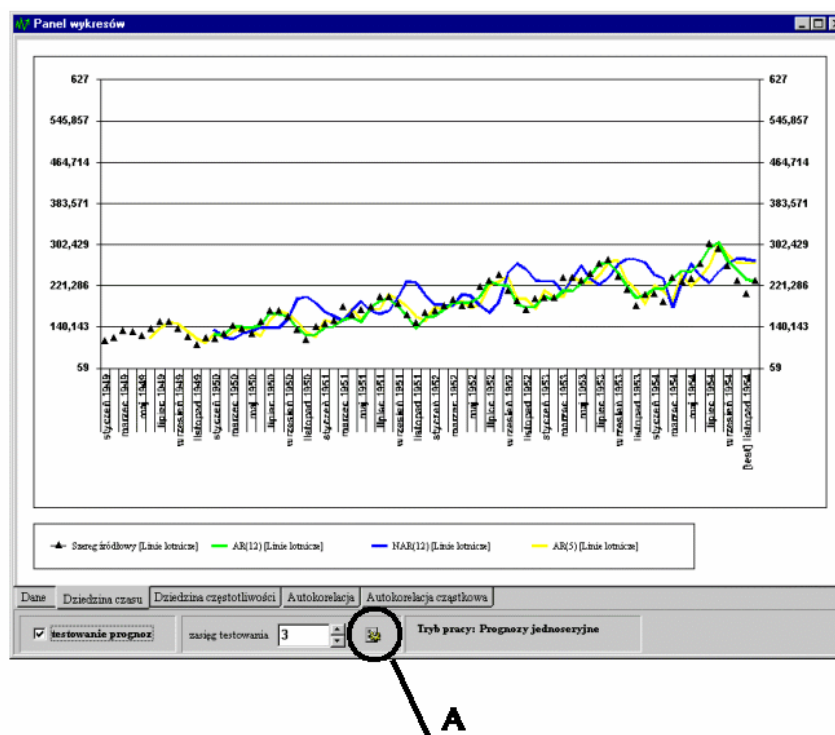
Grupa **Pomoc** umożliwia uzyskanie szczegółowych wyjaśnień odnośnie obsługi Neuronix'a oraz pozwala na połączenie z witryną internetową, na której znajdują się najnowsze informacje dotyczące produktów firmy AITECH oraz przykłady i uwagi Użytkowników.



Rys. 15. Grupa **Pomoc**

UŻYCIE MODELU


Użycie modelu jest możliwe poprzez naciśnięcie przycisku **A**, po wcześniejszym ustawieniu odpowiedniej liczby wyprzedzenia dla prognoz lub podczas testowania modelu.



Rys. 16. Użycie modelu

ARKUSZE KALKULACYJNE I GROMADZONIE DANYCH

W systemie Predyktor każdy nowo utworzony lub wczytany z dysku projekt powoduje otwarcie głównego okna, które zawiera wszystkie dane niezbędne w procesie identyfikacji parametrów, wyniki tej identyfikacji w postaci parametrów modeli oraz wyniki zastosowania modeli parametrycznych (np. autoregresja AR) i nieparametrycznych (np. dyskretna transformata Fouriera). W głównym oknie znajdują się również zakładki zawierające wizualizację tych danych w postaci wykresów. Dolna część okna głównego zawiera panel na którym znajdują się dodatkowe opcje oraz informacje dla użytkownika. Przykładowo dostępna jest opcja przełączania systemu podczas testowania oraz okienko umożliwiające zadanie horyzontu prognozy. Dostępna jest również informacja o trybie w jakim znajduje się system Predyktor. Dodatkowe opcje umieszczone są na poszczególnych zakładkach. W związku z tym są one widoczne wyłącznie po wybraniu właściwej zakładki. Dla zakładki **Dziedzina częstotliwości** jest to opcja wyboru wyświetlania części rzeczywistej, urojonej dyskretnego przekształcenia Fouriera, lub widma mocy ciągu czasowego. Dla zakładki **Dane** można przełączać się pomiędzy arkuszami zawierającymi dane wejściowe i wyniki obliczeń. Zakładka **Autokorelacja** i **Autokorelacja cząstkowa** zawierają opcje ustawienia liczby analizowanych wartości ciągów czasowych.



Rys. 17. Główne okno programu, widok dla wybranej zakładki **Dziedzina czasu**

PRZYGOTOWANIE DANYCH DO BUDOWY MODELU

Nazwy zakładek w arkuszach są dowolne, należy jednak zachować kolejność ich ułożenia w skoroszycie, która jest następująca:

- Arkusz do wprowadzania danych na podstawie których będzie identyfikowany model.
- Arkusz zawierający dane w postaci ciągów wyjściowych oraz ciągów źródłowych. Dane pochodzące z tego arkusza mogą być wizualizowane na wykresie czasowym. Można na ich podstawie utworzyć model nieparametryczny w dziedzinie częstotliwości.
- Arkusz zawierający utworzone modele oraz ich parametry.
- Arkusz zawierający funkcje autokorelacji poszczególnych ciągów czasowych zawartych w arkuszu danych wyjściowych.
- Arkusz zawierających ciąg wartości jako wynik funkcji autokorelacji cząstkowej dla danych (jednego ciągu) zawartych w arkuszu wprowadzania danych.

Wszystkie arkusze, poza arkuszem wprowadzania danych nie może być modyfikowane przez użytkownika. Istnieje możliwość kopiowania zawartości tych arkuszy poprzez schowek.

B74	229					
	A	B	C	D	E	F
1		we				
2		Linie lotnicze				
3	styczeń 1949	112				
4	luty 1949	118				
5	marzec 1949	132				
6	kwiecień 1949	129				
7	maj 1949	121				
8	czerwiec 1949	135				
9	lipiec 1949	148				
10	sierpień 1949	148				
11	wrzesień 1949	136				
12	październik 1949	119				
13	listopad 1949	104				
14	grudzień 1949	118				
15	styczeń 1950	115				
16	luty 1950	126				
17	marzec 1950	141				
18	kwiecień 1950	135				
19	maj 1950	125				
20	czerwiec 1950	149				
21	lipiec 1950	170				
22	sierpień 1950	170				
23	wrzesień 1950	158				
24	październik 1950	133				
25	listopad 1950	114				
26	grudzień 1950	140				
27	styczeń 1951	145				
28	luty 1951	150				
29	marzec 1951	178				
30	kwiecień 1951	163				
31	maj 1951	172				
32	czerwiec 1951	178				

Rys. 18. Wybranie zakładki **Dane** umożliwia dostęp do arkuszy danych zawierających pogupowane dane

	A	B	C	D	E
1	nazwy indeksu	Szereg źródłowy [Linie lotnicze]	AR(12) [Linie lotnicze]	NAR(12)	Regresja [Linie lotnicze]
2	styczeń 1949	112			112,5072298
3	luty 1949	118			114,490203
4	marzec 1949	132			116,4731762
5	kwiecień 1949	129			118,4561494
6	maj 1949	121			120,4391226
7	czerwiec 1949	135			122,4220957
8	lipiec 1949	148			124,4050689
9	sierpień 1949	148			126,3880421
10	wrzesień 1949	136			128,3710153
11	październik 1949	119			130,3539885
12	listopad 1949	104			132,3369616
13	grudzień 1949	118			134,3199348
14	styczeń 1950	115	126,4576785	133,2832914	136,302908
15	luty 1950	126	124,8799116	120,198579	138,2888812
16	marzec 1950	141	141,3979132	117,0722969	140,2688544
17	kwiecień 1950	135	140,2385572	127,5378583	142,2518276
18	maj 1950	125	138,6181885	131,7417112	144,2348007
19	czerwiec 1950	149	143,9273055	139,6517055	146,2177739
20	lipiec 1950	170	167,695989	138,267895	148,2007471
21	sierpień 1950	170	166,8495749	138,4878755	150,1837203
22	wrzesień 1950	158	159,9522511	156,0579183	152,1666935
23	październik 1950	133	135,048977	195,6486585	154,1496666
24	listopad 1950	114	123,104096	200,0414524	156,1326398
25	grudzień 1950	140	125,3647729	188,2242421	158,115613
26	styczeń 1951	145	139,2687843	171,1134905	160,0985862
27	luty 1951	150	141,4487272	161,7988721	162,0815594
28	marzec 1951	178	154,532957	152,1738548	164,0645326
29	kwiecień 1951	163	158,7263685	171,6921634	166,0475057
30	maj 1951	172	150,8151408	190,272463	168,0304789
31	czerwiec 1951	178	177,9411146	171,9743341	170,0134521
32	lipiec 1951	199	189,5604531	165,9607185	171,9964253

Rys. 19. Wybranie zakładki **ciągi wyjściowe** umożliwia dostęp do arkusza danych zawierającego pogupowane dane

W celu prawidłowego przygotowania arkusza wprowadzania danych należy mieć na uwadze rodzaj modelu który chemy zbudować. W zależności od rodzaju modelu (model ciągu czasowego, model obiektu) należy wprowadzić do arkusza indeks opisujący ciągi czasowe (opcjonalnie), ciągi czasowe wejściowe i/lub wyjściowe. Przykładowo błędne wprowadzenie tylko jednego ciągu czasowego dla modelu obiektu spowoduje wyświetlenie komunikatu o niewystarczającej liczbie ciągów czasowych.

Tabela. 1. Opis arkusza danych

	Rodzaj ciągu czasowego {we,wy}
	Nazwa wejścia ciągu czasowego {nazwa}
Kolumna opisu danych	Kolumna danych

Wstęp do analizy statystycznej


W rozdziale:

- Rozkład prawdopodobieństwa
- Opis statystyczny ciągu czasowego
- Interpretacja wybranych miar
- Analiza statystyczna w systemie Predyktor

Wstęp do analizy statystycznej


ROZKŁAD PRAWDOPODOBIEŃSTWA

Rozkład prawdopodobieństwa umożliwia nam ocenę ważnych cech ciągu czasowego. Rozkład jest w zasadzie budowany dla zmiennej ciągłej. W przypadku, gdy dysponujemy danymi empirycznymi wykreślenie rozkładu prawdopodobieństwa jest możliwe dla odpowiedniej licznej populacji. Alternatywą rozkładu jest histogram wykreślany dla zmiennej dyskretnej (grupowanej przedziałami). Użycie histogramu jest możliwe dla mniej licznej próbki całej populacji. Wykres rozkładu zbudowany jest z osi x , na której odkładane są wartości występujące w populacji oraz osi h , przedstawiającej najczęściej gęstość prawdopodobieństwa. Oznacza to dla wybranej wartości zmiennej ciągłej z osi x można określić prawdopodobieństwo jej wystąpienia w populacji. Histogram wykreślony dla danych empirycznych będących próbką z całej populacji pozwala na oszacowanie rozkładu prawdopodobieństwa tej populacji. W histogramie przedstawiana jest graficznie ilość wystąpień (częstość) jednostki lub ich grupy (przedział) w próbce populacji.



Rys. 20. Rozkład prawdopodobieństwa


Wykreślając histogram rozkładu zmiennej ciągłej, można dobrać skalę na osi rzędnych, aby łączna powierzchnia prostokątów, która reprezentuje całą populację była równa 1. Wtedy pola prostokątów są równe częstością jednostek w poszczególnych przedziałach. Można w ten sposób określić funkcję gęstości opisującą rozkład zmiennej ciągłej.



Rys. 21. Rozkład dla zmiennej uśrednianej przedziałami

OPIS STATYSTYCZNY CIĄGU CZASOWEGO

W statystyce mamy najczęściej do czynienia z opisem pewnych własności populacji reprezentowanej poprzez zbiór danych (histogram), przy pomocy modelu, którym jest rozkład prawdopodobieństwa. Najczęściej występującym rozkładem w odniesieniu do danych pomiarowych jest rozkład normalny (Gaussa).



Rys. 22. Graficzna reprezentacja rozkładu normalnego

Rozkład normalny wyraża zależność:

$$f(t) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(t-m)^2}{2\sigma^2}\right] \quad (3.1)$$

gdzie: μ i σ to momenty statystyczne rzędu pierwszego i drugiego dane odpowiednio wzorami (3.2) i (3.3):

$$\mu = \frac{1}{n} \sum_{i=1}^n y_i \quad (3.2)$$

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \quad (3.3)$$

Dodatkowo można wprowadzić inne miary oparte na momentach pierwszym i drugim oraz momenty wyższych rzędów:

- średnie odchylenie bezwzględne (ang. average deviation, mean absolute deviation)

$$a = \frac{1}{n} \sum_{i=1}^n |y_i - \bar{y}| \quad (3.4)$$

- skośność (ang. skewness)


$$s = \frac{1}{N} \sum_{i=1}^N \left[\frac{y_i - \bar{y}}{\sigma} \right]^3 \quad (3.5)$$

- kurtoza (ang. kurtosis)

$$s = \left\{ \frac{1}{N} \sum_{i=1}^N \left[\frac{y_i - \bar{y}}{\sigma} \right]^4 \right\} - 3 \quad (3.6)$$


INTERPRETACJA WYBRANYCH MIAR

Skośność można interpretować graficznie, w zależności od znaku jaki przyjmuje rozkład prawdopodobieństwa, jest on zniekształcony (przesunięty względem wartości średniej oraz asymetryczny).



Rys. 23. Graficzna reprezentacja skośności

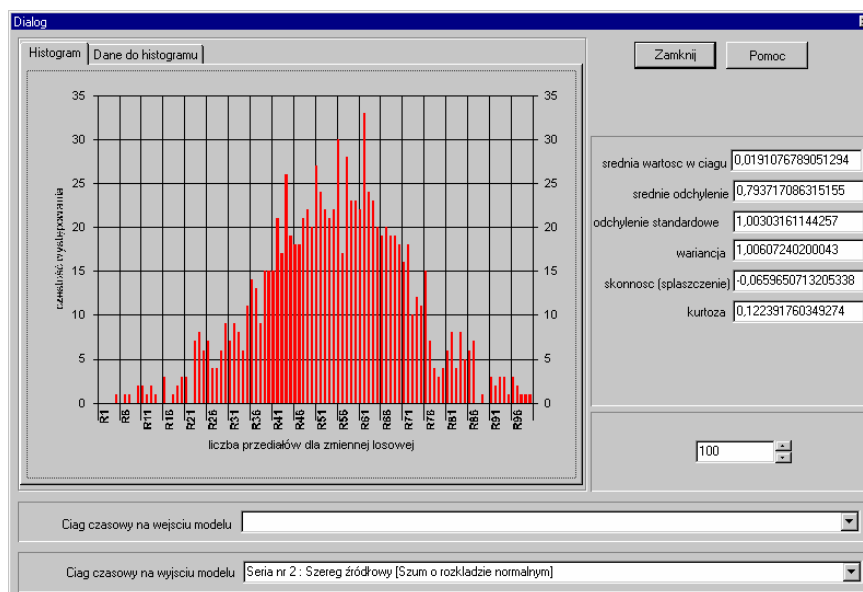
W podobny sposób, w zależności od znaku, można interpretować kurtozę, czyli moment rzędu czwartego.



Rys. 24. Graficzna reprezentacja kurtozy


ANALIZA STATYSTYCZNA W SYSTEMIE PREDYKTOR

System Predyktor posiada narzędzia niezbędne do wykonania wykresów rozkładów empirycznych w postaci histogramów, jak również umożliwia obliczenie podstawowych miar statystycznych i na ich podstawie wyrysowanie modelu rozkładu normalnego.



Rys. 25. Dialog umożliwiający przeprowadzenie analizy statystycznej ciągu czasowego danych wejściowych i wyjściowych

Dialog umożliwia wykreślenie histogramu o dowolnej liczbie przedziałów podając dodatkowo miary charakteryzujące rozkład prawdopodobieństwa dla wybranego ciągu czasowego wejściowego $u(t)$ lub wyjściowego $y(t)$. W przypadku modeli ciągów czasowych dostępny jest jedynie ciąg czasowy wyjściowy $y(t)$. Przykład histogramu uzyskanego dla wygenerowanego ciągu wyjściowego zawierającego realizacje procesu stochastycznego o rozkładzie zbliżonym do normalnego przedstawia rys. 26.



Rys. 26. Rozkład ciągu czasowego uzyskanego za pomocą generatora liczb losowych o rozkładzie normalnym dla parametrów $\mu=0$ oraz $\sigma=1$

4

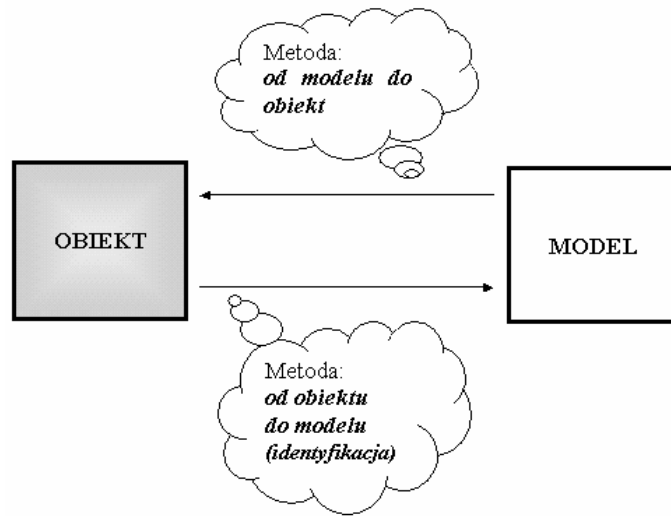
Metody budowy modeli w systemie Predyktor

W rozdziale:


- Jak powstaje model ?
- Modele parametryczne ciągów czasowych
- Modele parametryczne pełne
- Modele nieparametryczne ciągów czasowych
- Procedura budowy modelu

Metody budowy modeli w systemie Predyktor

JAK POWSTAJE MODEL ?



Rys. 27. Dwie główne drogi budowy modeli obiektów



Dla wielu zjawisk nie jest możliwe zbudowanie modeli przyczynowo-skutkowych, przykładami są następujące zjawiska [Bilińska, Figwer, 1995].

- Wycena akcji na giełdzie, gdzie cena jest uwarunkowana wieloma poznanymi czynnikami dla których stwierdzono dodatnią wartość korelacji oraz sprawdzono poprawność teoretyczną ich wpływu na cenę. Pomimo znajomości tych czynników nie jest możliwe zbudowanie poprawnego modelu wyceny akcji spełniającego kryterium jakości, przy których jest możliwe jego stosowanie.
- Zależność liczby plam pojawiających się na słońcu od natężenia promieniowania słonecznego. Do chwili obecnej nie jest możliwe poznanie praw rządzących tym zjawiskiem. Jednak jest dostępny ciąg czasowy odnotowanych obserwacji tych plam, tzw. ciąg Wolfera, który potwierdza cykliczność zjawiska i umożliwia budowę modelu prognostycznego na ich podstawie.

W przypadku identyfikacji modelu możemy mówić o **metodach parametrycznych** wymagających zdefiniowania struktury modelu poprzez podanie np. opóźnień oraz stopni wielomianów oraz **nieparametrycznych** określających samodzielnie parametry identyfikowanego modelu, np. analiza widmowa.

MODELE CIĄGÓW CZASOWYCH

Dla reprezentacji sygnału będącego realizacją procesu stochastycznego lub deterministycznego (jak również liniowego lub nieliniowego, gaussowskiego lub o innym rozkładzie) wykorzystamy **skalarny ciąg czasowy**, który można określić (na podstawie ciągu liczbowego) jako sekwencję liczb rzeczywistych

$$y(t); \quad t = \dots, -2, -1, 0, 1, 2, \dots \quad (4.1)$$

przyporządkowanych dyskretnym chwilom czasu iT ($i = \dots, -2, -1, 0, 1, 2, \dots$) gdzie T jest okresem próbkowania, a $y(i)$ jest i -tą próbką ciągu [Niederliński, Kacprzyk, Figwer, 1997]. Powyższy zapis można analogicznie rozszerzyć na

pojęcie **wektorowego ciągu czasowego** składającego się z pewnej liczby składowych ciągów czasowych. Wektorowy ciąg czasowy jest określony sekwencją m – elementowych wektorów o elementach będących liczbami rzeczywistymi [Niederliński, Kacprzyk, Figwer, 1997]

$$y(i) = \begin{bmatrix} y_1(i) \\ y_2(i) \\ \dots \\ y_m(i) \end{bmatrix}; \quad i = \dots, -2, -1, 0, 1, 2, \dots \quad (4.2)$$

Ze względu na występowanie zakłóceń można wyróżnić **deterministyczne** i **stochastyczne** modele ciągów czasowych. Deterministyczny model ciągu czasowego jest opisem zjawiska zmieniającego się w czasie zgodnie z odwzorowaniem: zdarzenia przeszłe \rightarrow zdarzenia przyszłe. Modele deterministyczne nie uwzględniają zaburzeń występujących w systemie. Przykład modelu deterministycznego ciągu czasowego odpowiadającego drganiom obiektu fizycznego przedstawia wzór (1). W rzeczywistości procesy deterministyczne nie istnieją, są pomocne podczas opisu zjawisk (zawsze są idealizacją zjawisk). Wszystkie realizacje procesu deterministycznego są takie same.

$$y(u) = \sin(2\pi u) \quad (4.3)$$

Poprzez stochastyczny model ciągu czasowego rozumiemy opis zjawiska zmieniającego się w czasie zgodnie z rozkładami prawdopodobieństwa. Każde zdarzenie ma określoną wartość prawdopodobieństwa. W związku ze stochastycznymi metodami modelowania procesów w ogólnym przypadku może istnieć nieskończenie wiele realizacji rozpatrywanego procesu. Rozróżniamy **stochastyczne stacjonarne modele ciągów czasowych**, dla których łączny rozkład prawdopodobieństwa dowolnego obszaru zbioru obserwacji nie powinien ulegać zmianie przy przesunięciu wszystkich czasów obserwacji o k całkowitych jednostek do przodu lub do tyłu oraz **stochastyczne niestacjonarne modele ciągów czasowych** nie spełniające tego warunku. Model stochastyczny opisuje wartość średnią wokół której oscyluje wartości ciągu czasowego oraz wariancja będąca miarą rozrzutu tych wartości w stosunku do poziomu średniej.

MODELE PEŁNE (OBIEKTÓW)


Modele pełne są opisywane poprzez wejściowe ciągi czasowe i wyjściowe ciągi czasowe. Przykładem modelu pełnego jest regresja.

PROCEDURA BUDOWY MODELU

Identyfikacja rozumiana w szerszym kontekście jest procesem iteracyjnym obejmującym poza identyfikacją właściwą również testowanie i weryfikację modelu. W tym znaczeniu na identyfikację składają się następujące etapy [Bilińska, Figwer, 1995]:

- (a) Etap wyboru modelu z pośród modeli: deterministycznych, stochastycznych, rozmytych, które mogą być: liniowe lub nieliniowe, przybliżone lub dokładne oraz stacjonarne lub niestacjonarne.
- (b) Identyfikacja struktury i parametrów.
- (c) Testowanie modelu.
- (d) Weryfikacja modelu.
- (e) Jeżeli niepowodzenie weryfikacji to korekta.

Powyższe etapy składają się na eksperyment identyfikacyjny.



Rys. 28. Uproszczona procedura identyfikacji modelu procesu

REALIZACJA WYBRANYCH METOD W SYSTEMIE PREDYKTOR

W systemie Predyktor zostały wykorzystane wybrane metody z teorii identyfikacji systemów oraz z teorii ekonometrii. Dla opisu struktury modelu wykorzystano postać wielomianową oraz sieci neuronowej. W przypadku postaci wielomianowej parametry są przedstawiane jako **współczynniki wielomianu**, w przypadku sieci neuronowej w postaci **zbioru wag**.

1. Dla modelowania ciągów czasowych zastosowano model autoregresji o postaci

$$A(z^{-1})y(t) = e(t) \quad (4.4)$$

określonej wielomianem

$$A(z^{-1}) = 1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_{dA} z^{-dA} \quad (4.5)$$

gdzie z^{-1} oznacza jednostkowe opóźnienie sygnału, dA jest rzędem wielomianu modelującego ciąg czasowy $y(t)$, $e(t)$ zakłócenia o rozkładzie normalnym. W skrócie taki model będziemy zapisywać jako AR(dA). W trybie prognoz wieloseryjnych możliwe jest modelowanie wektorowych ciągów czasowych składających się z N niezależnych skalarnych ciągów czasowych o takich samych własnościach tj. stopniu wielomianu dA podczas tworzenia modelu, które to własności mogą być zmieniane podczas dalszego etapu weryfikacji modelu

$$A^{(n)} = \begin{bmatrix} A^{(1)}(z^{-1}) = 1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_{dA} z^{-dA} \\ A^{(2)}(z^{-1}) = 1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_{dA} z^{-dA} \\ \vdots \\ A^{(N)}(z^{-1}) = 1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_{dA} z^{-dA} \end{bmatrix} \quad (4.6)$$

2. Do modelowania zjawisk, dla których znane są przyczyny powodujące ich powstawanie (istnieją zmienne objaśniające) możliwe jest zbudowanie modelu pełnego (modelu obiektu) o postaci

$$A(z^{-1})y(t) = B(z^{-1})u(t) + e(t) \quad (4.7)$$

gdzie wielomiany

$$A(z^{-1}) = 1 + a_1 z^{-1} + a_2 z^{-2} + \dots + a_{dA} z^{-dA} \quad (4.8)$$

$$B(z^{-1}) = b_0 + b_1 z^{-1} + b_2 z^{-2} + \dots + b_{dB} z^{-dB} \quad (4.9)$$

Przyjęto w obecnej wersji systemu Predyktor ograniczenie stopnia dla wielomianu dA do rzędu zerowego o postaci

$$A(z^{-1}) = 1, \quad (4.10)$$

oraz dla wielomianu dB do rzędu pierwszego o postaci

$$B(z^{-1}) = b_0 + b_1 z^{-1}, \quad (4.11)$$

co upraszcza zapis (4.7) następująco

$$y(t) = B(z^{-1})u(t) + e(t), \quad (4.12)$$

i dalej prowadzi do znanego z ekonometrii zapisu równania regresji

$$y(t) = b_0 + b_1 u(t-1) + e(t). \quad (4.13)$$

3. Możliwość modelowania trendów

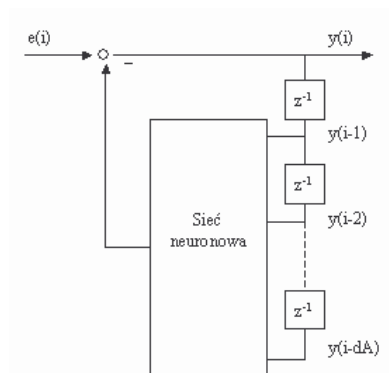
Trend jest składową stałą o postaci wielomianowej rozszerzeniem trendów liniowych są trendy wyższych rzędów o ogólnej postaci

$$y(t) = z_0 + z_1 u(t-1) + z_2 u^2(t-1) + \dots + z_{dz} u^{dz}(t-1) \quad (4.14)$$

powyższe równanie jest **nieliniowe ze względu na zmienną $u(t-1)$** .


4. Modele nieliniowe

Modele nieliniowe budowane przy pomocy sieci neuronowej w porównaniu do modeli liniowych, będą uwzględniały **nieliniowość dynamiki modelu**.



Rys. 29. Schemat modelu NAR ciągu czasowego

Rys. 27. przedstawia realizację modelu ciągu czasowego w oparciu o sieć neuronową przyjętą w systemie Predyktor, gdzie z^{-1} oznacza jednostkowe opóźnienie sygnału, $e(i)$ jest białym szumem dla modelu stochastycznego.



Rys. 30. Ogólniejszy model NARX obiektu

MODELE NIEPARAMETRYCZNE CIĄGÓW CZASOWYCH

Model ciągu czasowego w dziedzinie częstotliwości można wyznaczyć z danej realizacji ciągu czasowego przy pomocy przekształcenia zwanego *dyskretną transformacją Fouriera* (ang. *Discrete Fourier Transforms*)

$$Y(j\omega T) = T \sum_{i=-\infty}^{\infty} y(i) e^{-j\omega T i}, \quad (4.15)$$

lub w zapisie operatorowym, gdzie $F\{\cdot\}$ oznacza operator dyskretnej transformaty Fouriera

$$Y(j\omega T) = F\{y(i)\} = |Y(j\omega T)| e^{-j\varphi(\omega T)}, \quad (4.16)$$

co pozwala na wyróżnienie między innymi:

- widma (ang. *spectrum*), gdzie rzędną jest część rzeczywista i urojona transformaty Fouriera

$$Y(j\omega T), \quad (4.17)$$

- widma amplitudowego (ang. *amplitude spectrum*), gdzie rzędną jest moduł transformaty Fouriera

$$|Y(j\omega T)|, \quad (4.18)$$

- widma fazowego (ang. *phase spectrum*) gdzie rzędną jest faza transformaty Fouriera

$$\varphi(\omega T), \quad (4.19)$$

- widma energetycznego, gdzie rzędną jest kwadrat modułu transformaty Fouriera

$$[Y(j\omega T)]^2, \quad (4.20)$$

- widma mocy PSD (ang. *Power Spectrum Density*) nazywanego *periodogramem*

$$\frac{1}{T} [Y(j\omega T)]^2, \quad (4.21)$$

gdzie T jest czasem próbkowania sygnału. W praktyce korzystamy najczęściej z szybkiego przekształcenia Fouriera FFT (ang. *Fast Fourier Transforms*) co pociąga za sobą wyznaczenie jedynie pewnego estymatora (oceny) widma w postaci

$$\hat{Y}_N(j\omega T) = F_N\{y(i)\} = T \sum_{i=0}^{N-1} y(i) e^{-j\omega T i} \quad (4.22)$$

gdzie $F_N\{\cdot\}$ operator dyskretnej transformacji Fouriera ciągu N próbek.

MODELE LINIOWE I NIELINIOWE - PORÓWNANIE

Sieć neuronowa pozwala na budowę modeli nieliniowych. Umożliwia to modelowanie zjawisk rzeczywistych lepiej niż przy wykorzystaniu klasycznych regresyjnych modeli liniowych. W celu zaprezentowania przykładu identyfikacji modelu nieliniowego wygenerowano dane uczące w oparciu o równania różnicowe opisujące system liniowy oraz nieliniowy. System liniowy przedstawia się następująco

$$y(t+2) = 0.7y(t+1) - 0.1y(t) + u(t), \quad (4.23)$$


natomiast system nieliniowy

$$y(t+1) = \frac{y(t)}{1+y^2(t)} + u^3(t). \quad (4.24)$$


Sygnal wejściowy zostanie utworzony ze złożenia dwóch przebiegów sinusoidalnych

$$u(t) = \sin\left(\frac{2\pi t}{25}\right) + \sin\left(\frac{2\pi t}{10}\right) \quad (4.25)$$


Zadaniem utworzonego modelu będzie odwzorowywanie wejście na wyjście w oparciu o dane pochodzące z symulacji systemu liniowego i nieliniowego.



Rys. 31. Ogólny model systemu



Rys. 32. Sygnal wejściowy $u(t)$ wygenerowany w oparciu o zależność (4-25)




Rys. 33. Wyjście modelu liniowego (linia ciągła) i nieliniowego (linia przerywana)


G8							
Typ	A	B	C	D	E	F	G
Nazwa	we t - 1	we t	wy t + 1	we u-1	we u		
3		0,5852738	3,377424		0,8364751		
4	0,5852738	3,377424	4,6477849	0,8364751	1,4328102		
5	3,377424	4,6477849	3,1428267	1,4328102	1,6356036		
6	4,6477849	3,1428267	1,1491716	1,6356036	1,4321132		
7	3,1428267	1,1491716	0,5642484	1,4321132	0,9510565		
8	1,1491716	0,5642484	0,4280178	0,9510565	0,4102415		
9	0,5642484	0,4280178	0,3616474	0,4102415	0,0312307		
10	0,4280178	0,3616474	0,3259199	0,0312307	-0,046229		
11	0,3616474	0,3259199	0,4976986	-0,046229	0,182728		
12	0,3259199	0,4976986	1,2723672	0,182728	0,5877853		
13	0,4976986	1,2723672	1,7329581	0,5877853	0,9559098		
14	1,2723672	1,7329581	0,9958931	0,9559098	1,0763897		
15	1,7329581	0,9958931	0,5105946	1,0763897	0,8257233		

Rys. 34. Zapis pliku w postaci opóźnionych wartości wejścia i wyjścia

W celach porównawczych wykorzystany zostanie liniowy model ARX(2,2,1) oraz nieliniowy model NARX(2,2,1) oparty na sztucznej sieci neuronowej zbudowanej w systemie Neuronix.



Rys. 35. Rezultat modelowania zależności nieliniowej przy wykorzystaniu systemu Neuronix



Rys. 36. Struktura sieci neuronowej użytej do zbudowania modelu NARX(2,2,1)

Przykłady prognoz

W rozdziale:

- Charakterystyka trybów pracy
- Tryb prognoz jednoseryjnych dla modeli ciągów czasowych
- Tryb prognoz jednoseryjnych dla modeli pełnych
- Tryb prognoz wieloseryjnych dla modeli ciągów czasowych


Przykłady prognoz

CHARAKTERYSTYKA TRYBÓW PRACY

System Predyktor umożliwia wykonywanie prognoz dla wielu różnych postaci modeli, przede wszystkim dla modeli ciągów czasowych i modeli pełnych (obiektów, zjawisk). Przyjęcie danego trybu pracy powoduje konsekwentne jego stosowanie podczas całego okresu życia projektu. Oznacza to brak możliwości zmiany trybu pracy po jego utworzeniu. W dalszej części instrukcji zostały przedstawione podstawowe trzy tryby pracy.


TRYB PROGNOZ JEDNOSERYJNYCH DLA MODELI CIĄGÓW CZASOWYCH

W celu zaprezentowania różnych technik prognostycznych rozpatrzmy model szeregu czasowego utworzony na podstawie danych zamieszczonych w literaturze [Box, Jenkins, 1983] .




Rys. 37. Ciąg czasowy zawierający dane dotyczące przewozów liniami lotniczymi

Przyjrzyjmy się teraz jego histogramowi




Rys. 38. Empiryczny rozkład danych z ciągu danych o liczbie przewozów

Teraz możemy utworzyć jego model nieparametryczny, wykorzystując funkcję autokorelacji




Rys. 39. Funkcja autokorelacji jako charakterystyka procesu

Oceniając funkcję autokorelacji oraz histogram możemy stwierdzić występowanie niestacjonarności w procesie. Wygląd ciągu czasowego po usunięciu niestacjonarności przedstawia rys. 38.




Rys. 40. Szereg czasowy po usunięciu trendu metodą różnicowania



Rys. 41. Funkcja autokorelacji szeregu czasowego po usunięciu trendu metodą różnicowania

Różnicowanie źródłowego ciągu czasowego poprawiło również jego własności statystyczne, poza „ogonami” rozkład jest zbliżony do normalnego.




Rys. 42. Histogram szeregu czasowego po usunięciu trendu metodą różnicowania


W dalszym ciągu zostaną przedstawione dwa warianty budowy modelu prognostycznego dla szeregu czasowego z trendem oraz bez trendu.

Model autoregresji

Dla określenia prawidłowej struktury modelu należy dysponować informacjami jakościowymi dotyczącymi modelowanego procesu, wykorzystać do tego celu dostępną w systemie Predyktor funkcję autokorelacji resztkowej lub przeprowadzić eksperyment polegający na intuicyjnym dobraniu wartości opóźnienia. Prognozę dla domyślnej wartości parametru opóźnienia modelu $AR(dA)$, gdzie $dA=2$, przedstawia rys. 39.


Rys. 43. Model $AR(2)$ dla prognozy z wyprzedzeniem 12 okresów

Sytuacja przedstawiona na rys. 39 jest wynikiem niedoparametryzowania modelu, należy więc przyjąć inną liczbę parametrów. W tym celu możemy posłużyć się informacją jakościową dotyczącą prognozowanego zjawiska, wiedząc że szereg reprezentuje liczbę sprzedanych biletów w okresach miesięcznych można przyjąć rząd modelu jako pewien powtarzający się okres jednego roku. Podobna liczba parametrów może zostać przyjęta po obserwacji wykresu funkcji korelacji częściowej (por. rys. 40).



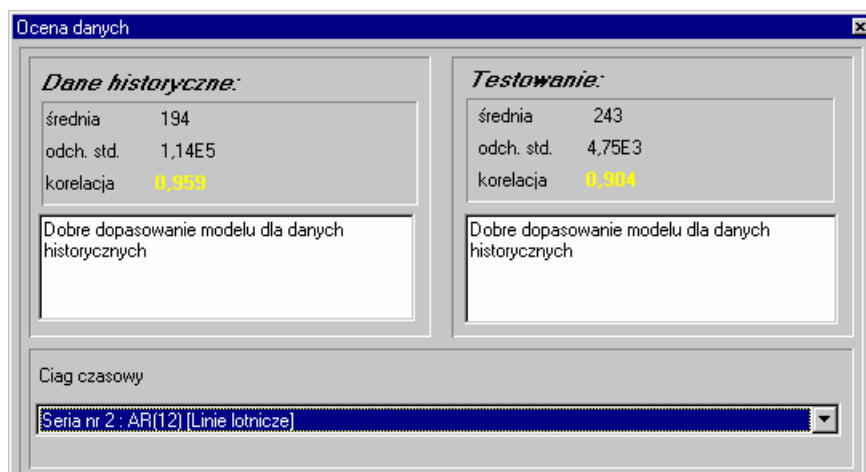
Rys. 44. Wykres funkcji autokorelacji cząstkowej

Po zwiększeniu rzędu modelu do $AR(dA)$ gdzie $dA=12$, otrzymujemy model szeregu czasowego, którego zastosowanie pozwala otrzymać rezultaty przedstawione na rys. 41.



Rys. 45. Model AR(12)


Ocena dokładności prognozy jest możliwa do przeprowadzenia w trybie testowania, podczas którego pewną część wejściowego ciągu czasowego wyłączamy ze zbioru na podstawie którego identyfikowane są parametry modelu



Rys. 46. Ocena dokładności modelu podczas testowania


Model regresji

W celu porównania efektów prognozy przeprowadzonej przy użyciu modelu autoregresji utworzymy kolejny model regresji liniowej

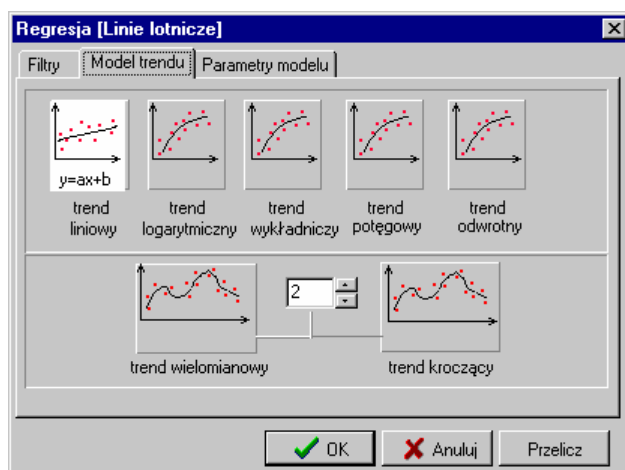


Rys. 47. Prognoza wykonana przy użyciu trendu liniowego

Istnieje możliwość zmiany trendu liniowego na nieliniowy – wielomianowy, lub inne trendy nieliniowe (por. rys. 47).




Rys. 48. Wykorzystanie trendu logarytmicznego



Rys. 49. Widok właściwości dostępnych modeli trendu

Dla utworzonego modelu można podglądać wartości parametrów. Opcja jest dostępna z poziomu dialogu właściwości modelu.



Rys. 50. Parametry modelu regresji

Wśród dostępnych metod regresji występują metody trendów prostych oraz trendów segmentowych. W przypadku trendów segmentowych trend jest obliczany jako złożenie pewnej liczby modeli lokalnych regresji prostoliniowej.

System Predyktor wykorzystuje następujący model trendu liniowego:

$$y = ax + b . \quad (5.1)$$

System Predyktor wykorzystuje następujące modele trendów nieliniowych:
Model trendu logarytmicznego,

$$y = a \cdot \ln(x) + b , \quad (5.2)$$

Model trendu wykładniczego,

$$y = a \cdot \exp(bx) , \quad (5.3)$$

Model trendu potęgowego,

$$y = ax^b , \quad (5.4)$$


Model trendu odwrotnego,

$$y = \frac{1}{ax + b} , \quad (5.5)$$

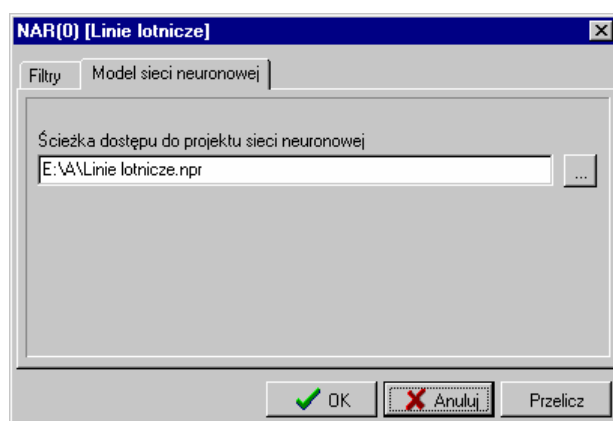
Model trendu wielomianowego

$$y = a_0 + \sum_{i=1} a_i x^i . \quad (5.6)$$

Model sieci neuronowej




Rys. 51. Model sieci neuronowej NAR(12)(trójkąty - ciąg oryginalny, krzyżyki ciąg prognozowany)




Rys. 52. Właściwości sieci neuronowej


Przegląd powyższych metod został wykonany na oryginalnym ciągu czasowym reprezentującym niestacjonarny proces losowy. Usuwając z ciągu trend można polepszyć jakość prognozy oraz spełnić warunki dotyczące prawidłowej drogi budowy modelu prognostycznego. Zestawienie porównawcze wyników dla modelu autregresji oraz sieci neuronowej przedstawiają poniższe rysunki



Rys. 53. Zróżnicowane ciągi czasowe dla danych źródłowych oraz modeli autoregresji i neuronowego




Rys. 54. Ciągi czasowe dla danych źródłowych oraz modeli autoregresji i neuronowego dla wyprzedzenia (prognozy) o 36 okresów



Rys. 55. Funkcja autokorelacji dla ciągów zróżnicowanych

TRYB PROGNOZ JEDNOSERYJNYCH DLA MODELI PEŁNYCH

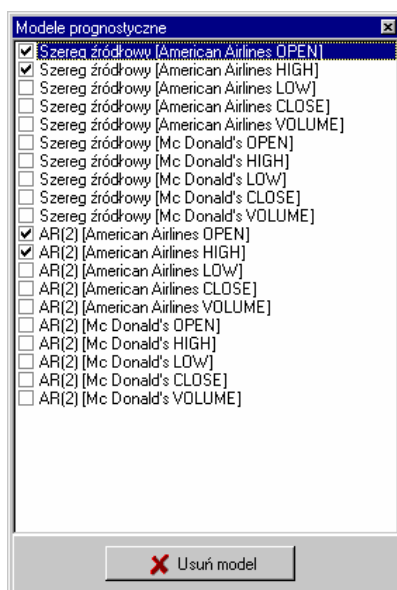
Modele takie są stosowane jeżeli dysponujemy zbiorem obserwacji wejścia i wyjścia obiektu. Oznacza to że musi istnieć zbiór zmiennych objaśniających dane zjawisko oraz zbiór zmiennych objaśnianych. Mamy wtedy do czynienia w ogólnym przypadku z modelem o wielu wejściach i wyjściach. System Predyktor umożliwia budowanie modeli o wielu wejściach i jednym wyjściu. Rozważmy przykład prognozy wybranego stężenia zanieczyszczenia związkiem chemicznym np. tlenkiem węgla (CO). Interesuje nas w tym wypadku możliwość prognozy tego zanieczyszczenia w dniu następnym (predykcja jednokrokowa). Można określić zbiór zmiennych wejściowych, które mogłyby mieć wpływ na stężenie tego zanieczyszczenia. Do takiego zbioru możemy zaliczyć stężenie innych zanieczyszczeń w dniu względem którego wykonujemy prognozę, siłę i kierunek wiatru, temperaturę, dzień tygodnia, wilgotność powietrza itp. Rys. 50 przedstawia przykładowy przebieg stężenia CO.



Rys. 56. Przebieg jednokrokowej prognozy stężenia CO

TRYB PROGNOZ WIELOSERYJNYCH DLA MODELI CIĄGÓW CZASOWYCH

Stosowanie wieloseryjnego trybu pracy jest zalecane, jeżeli użytkownik posiada dane dotyczące wielu prognozowanych zjawisk. Tryb będzie więc szczególnie przydatny do jednoczesnej prognozy kursów wielu akcji na giełdzie, danych przedsiębiorstwa z wielu oddziałów itp.



Rys. 57. Menadżer zawiera wiele modeli ciągów czasowych

Obsługa systemu Predyktor

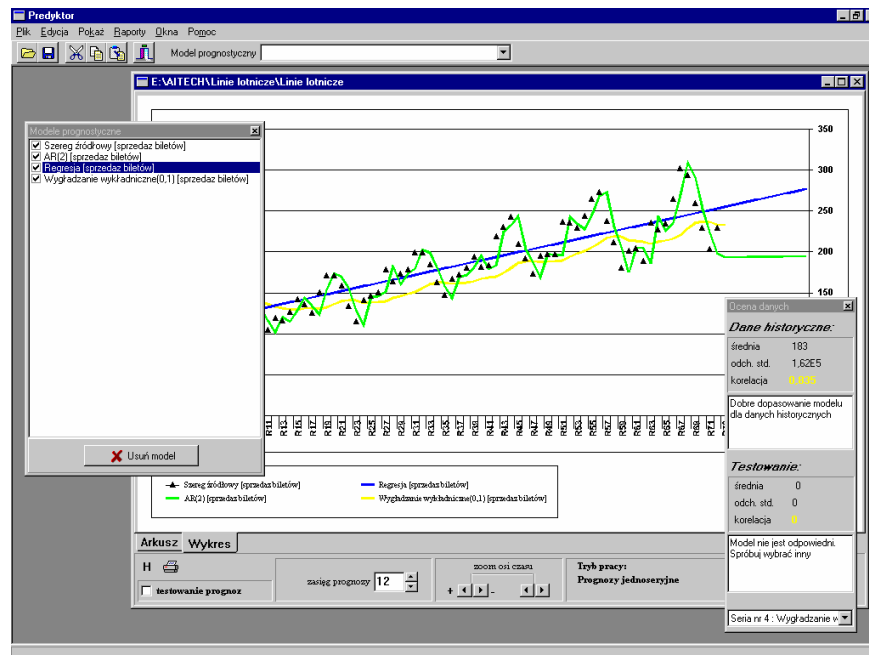
W rozdziale:

- Dostępne opcje w systemie Predyktor
- Utworzenie nowego projektu
- Menadżer modeli prognostycznych
- Dialog właściwości modelu
- Generowanie raportów

Obsługa systemu Predyktor

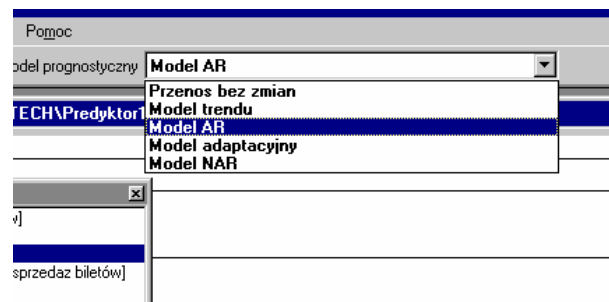
DOSTĘPNE OPCJE W SYSTEMIE PREDYKTOR

Główne okno systemu Predyktor pozwala na dostęp do podstawowych opcji systemu.



Rys. 58. Widok okna głównego w systemie Predyktor

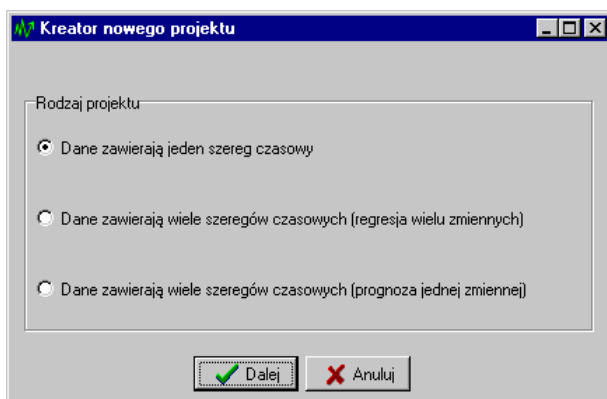
Korzystając z listy rozwijanej możliwy jest wybór modelu prognostycznego



Rys. 59. Lista rozwijana z dostępnymi modelami

UTWORZENIE NOWEGO MODELU

Przed utworzeniem nowego modelu należy ustalić jakimi dysponujemy danymi, czy są to dane zawierające szereg czasowy, wiele ciągów czasowych lub model pełny. W zależności od rodzaju danych wybieramy określony tryb pracy, w którym projekt znajduje się aż do usunięcia.



Rys. 60. Pierwszy etap pracy z kreatorem nowego projektu

MENADŻER MODELI PROGNOSTYCZNYCH

Menadżer modeli progностycznych, zawiera spis wszystkich modeli progностycznych użytych w danym projekcie. Podwójne kliknięcie na wybranym modelu powoduje przejście do właściwości wybranego modelu. Przycisk **Usuń model** powoduje usunięcie zaznaczonego modelu.

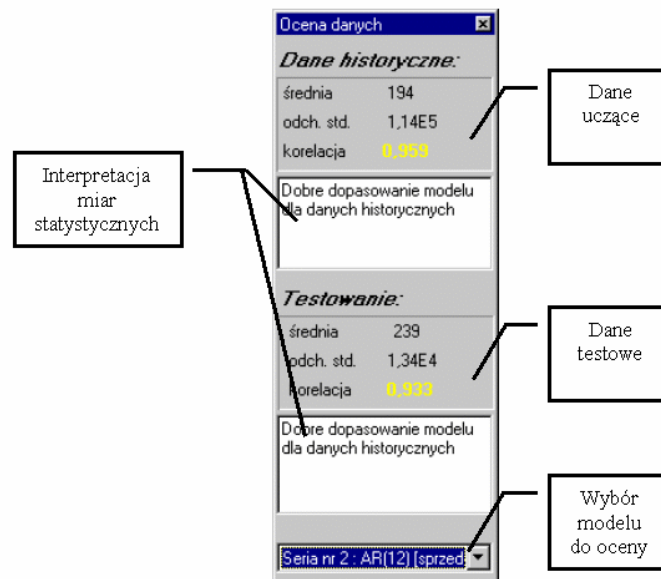


Rys. 61. Menadżer prognoz

Ocena dokładności danych wygenerowanych przez model szeregu czasowego jest możliwa przy pomocy okienka **Ocena danych**. W okienku znajdują się dwa pola w których widoczne są rezultaty oceny danych użytych do identyfikacji parametrów modelu oraz danych testowych które są wynikiem zastosowania modelu. Dane zostały odniesione do danych źródłowych na podstawie których został zbudowany danych model. Dostępna jest ocena w postaci miar statystycznych takich jak:

- średnia,
- odchylenie standardowe,
- korelacja.

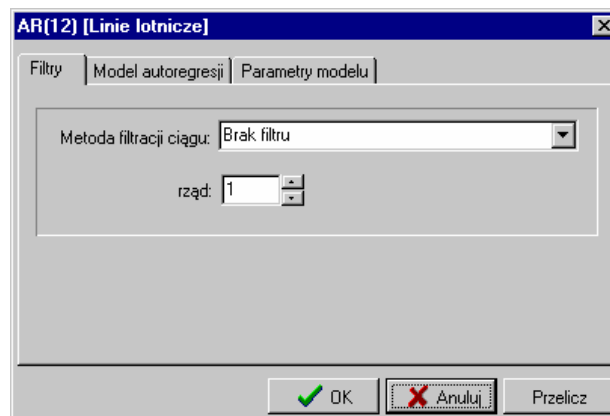
Testowanie danych jest możliwe tylko wtedy, jeżeli program znajduje się w trybie testowania, podczas którego część szeregu źródłowego jest traktowana jako nieznaną i służy do sprawdzenia dokładności prognozy.



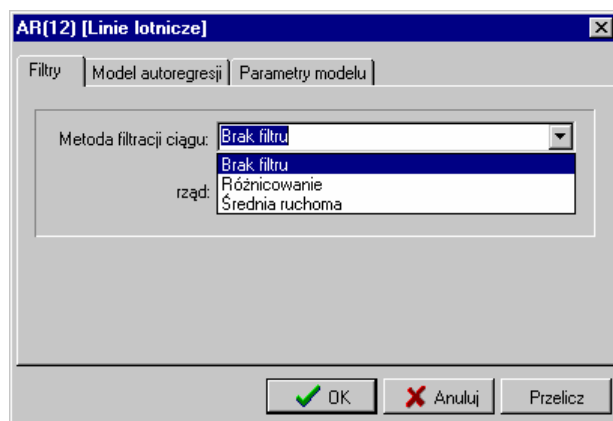
Rys. 62. Panel oceny danych prognostycznych

DIALOG WŁAŚCIWOŚCI MODELU


Dialog posiada zmienną liczbę zakładek. Jeżeli użytkownik wybierze określony model pojawiają się właściwości pogrupowane tematycznie w postaci zakładek odpowiednie do wybranego modelu. Dla każdej metody budowy modelu ciągu czasowego dostępna jest zakładka wspólna, zawierająca opcje umożliwiające ocenę danych oraz operacje preprocessingu, czyli przygotowania danych. Do podstawowych możliwości w zakresie przygotowania danych należy zaliczyć usuwanie trendu oraz wygładzanie danych przy pomocy średniej ruchomej. Decyzja jaką operację należy przeprowadzić zależy od rodzaju prognozy jaką chcemy wykonać.



Rys. 63. Wspólna zakładka modelu szeregu czasowego



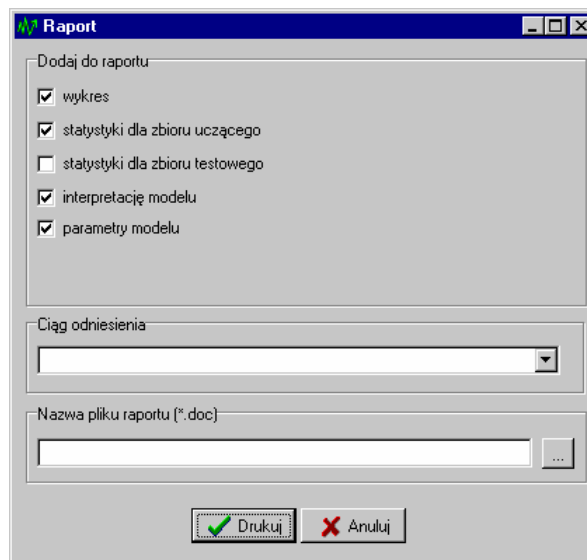
Rys. 64. Wybór odpowiedniego filtru danych



Rys. 65. Rezultaty użycia metod korekcyjnych

GENEROWANIE RAPORTÓW


Opcja generowania raportów w oparciu o wykonane modele ciągów czasowych oraz modele pełne pozwala wizualizować dane oraz miary statystyczne charakteryzujące te dane. Wybór miar jest możliwy poprzez zaznaczanie poszczególnych opcji przy pomocy odpowiednich pól: statystyki dla zbioru uczącego, statystyki dla zbioru testowego, interpretacja modelu, parametry modelu. Wykres zawiera prognozę oraz pokazuje dopasowanie modelu dla danych uczących, ponadto istnieje możliwość uwzględnienia ciągów referencyjnych w postaci



Rys. 66. Wygląd dialogu określania zawartości raportu


ANALIZA PRZY POMOCY TRANSFORMACJI FOURIERA

W celu wykorzystania transformaty Fouriera należy wybrać zakładkę **Dziedzina częstotliwości**, pozwoli to na obserwację widma ciągu czasowego które zostało zaznaczone w okienku menadżera modeli.

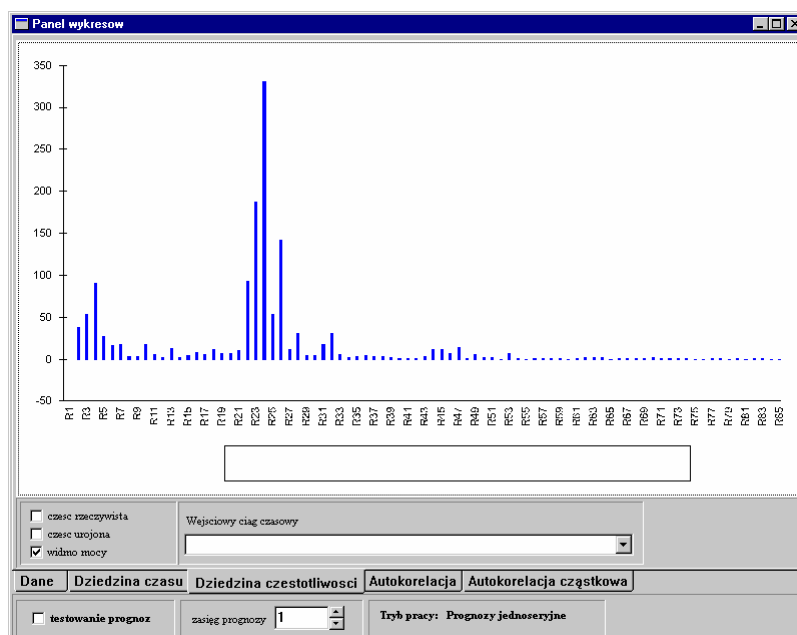


Rys. 67. Zakładka z wizualizacją wyników dyskretnego przekształcenia Fouriera

Przykładem poszukiwania okresowości w sygnale jest ciąg czasowy zawierający zapis cykli słonecznych.



Rys. 68. Wykres aktywności słońca



Rys. 69. Powiększenie fragmentu dyskretnego przekształcenia Fouriera wykonanej na podstawie danych aktywności słońca

7

Analiza sygnałów w dziedzinie częstotliwości

W rozdziale:

- Podstawowe informacje praktyczne
- Przykład analizy

Analiza sygnałów w dziedzinie częstotliwości

PODSTAWOWE INFORMACJE PRAKTYCZNE

Z dyskretną transformatą Fouriera przekształcającą realizację ciągu czasowego do dziedziny częstotliwości wiąże się kilka praktycznych uwag, których znaczenie jest istotne z punktu widzenia możliwości interpretacji uzyskanego obrazu w dziedzinie częstotliwości. Poniższy przykład powinien wyjaśnić wiele wątpliwości.

Przykład 1

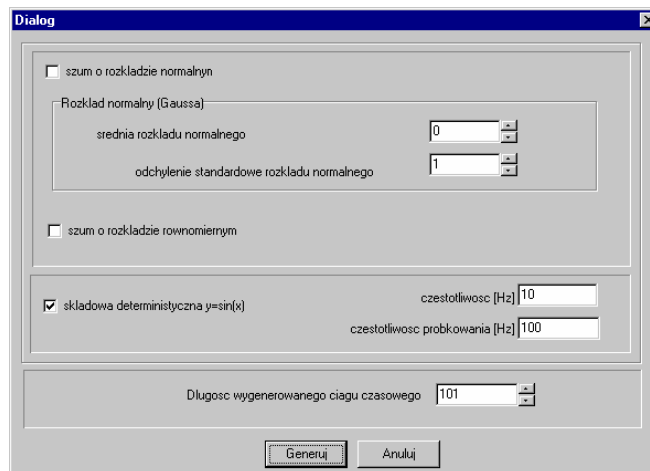
Wykonajmy operację transformacji Fouriera dla skończonego ciągu czasowego, uzyskanego w wyniku zastosowania generatora dostępnego w systemie Predyktor. Pamiętając że zgodnie z własnościami transformaty Fouriera najwyższa częstotliwość f_{\max} , możliwa do zaobserwowania

$$f_{\max} = \frac{f_s}{2} \quad (6.1)$$

gdzie f_s częstotliwość próbkowania sygnału ciągłego, lub częstotliwość występowania zdarzeń dyskretnych, co odnosi się głównie do danych ekonomicznych z natury dyskretnych. W celu wygenerowania przykładowego sygnału sinusoidalnego przyjmujemy $f_{\max} > f = 10$ [Hz], $f_s = 100$ [Hz] oraz $N = 100$ dyskretnych próbek. Taka liczba próbek jest wynikiem konieczności zamknięcia przedziałów początkowego i końcowego dziedziny funkcji w celu uwzględnienia pełnych okresów. Ciąg czasowy $y(t)$ zostanie wygenerowany w oparciu o zależność


$$y(t) = \sin(2\pi ft + \varphi) \quad (6.2)$$

gdzie f - częstotliwość generowanego sygnału, φ - faza początkowa równa zero.




Rys. 70. Generator ciągów czasowych

Po przełączeniu się na zakładkę **dziedzina częstotliwości** można obserwować poszczególne składowe widma: rzeczywistą i urojoną




Rys. 71. Składowa rzeczywista widma




Rys. 72. Składowa urojona

Można wyznaczyć na podstawie widma ciągu czasowego również widmo mocy, które wygląda następująco



Rys. 73. Widmo mocy ciągu czasowego


Jeżeli w naszym przykładzie zmienimy liczbę próbek sygnału na różną od $N = 100$, to wtedy funkcja sinus nie będzie odpowiednio gładka na końcach przedziałów i spowoduje to rozmycie się prążka widma na inne sąsiednie częstotliwości. Przykład rozmycia widma mocy rozpatrywanego sygnału dla zmienionej liczby próbek przedstawia rys. 68.



Rys. 74. Widmo mocy ciągu czasowego o niepełnym okresie

PODSTAWOWE INFORMACJE PRAKTYCZNE

Przykład analizy zostanie wykonany w oparciu o dane źródłowe dotyczące przewozów liniami lotniczymi. Zakładamy, że źródłowy ciąg został zróżnicowany w celu usunięcia niestacjonarności. Otrzymamy następujący postać ciągu czasowego w dziedzinie częstotliwości.



Rys. 75. Widmo mocy ciągu czasowego z danymi o przewozach liniami lotniczymi

Wiedząc, że dane były próbkowane (pobierane) z częstotliwością miesięczną można odpowiednio wyskalować wykres i przyjąć jednostkę częstotliwości jako [miesiąc/rok]. Chcąc obliczyć długości podstawowych okresów w ciągu powinniśmy użyć zależności


$$T = \frac{1}{f} \quad (6.3)$$

gdzie f jest częstotliwością danej harmoniki oraz T jest okresem danej harmoniki. Przykładową długość wyznaczmy dla pierwszych dwóch podstawowych okresów. Pierwsza harmonika o częstotliwości $f_1 = 0.98$ [1/rok] określa okres T_1

$$T_1 = \frac{1}{f_1} = \frac{1}{0.98} \approx 1.02 \text{ [rok]} \quad (6.4)$$

oraz druga harmonika

$$T_2 = \frac{1}{f_2} = \frac{1}{1.9} \approx 0.52 \text{ [rok]} \quad (6.5)$$



Rys. 76. Widmo mocy ciągu czasowego z danymi o przewozach liniami lotniczymi

Informacje uzupełniające

W rozdziale:


- Podstawowe klasyfikacje modeli
- Koncepcja modelu autoregresji
- Identyfikacja modeli ciągów czasowych i obiektów (zjawisk)

Informacje uzupełniające

PODSTAWOWE KLASYFIKACJE MODELI

Podstawowy podział modeli obejmuje ich klasyfikację ze względu na liczbę wejść i wyjść. Do najbardziej rozpowszechnionych modeli mających duże znaczenie praktyczne należą tzw. modele MISO (ang. Multiple Input Single Output) o wielu wejściach i jednym wyjściu, czyli liczbie uwzględnianych zmiennych z otoczenia oraz wyjściach wysyłających informacje do otoczenia. Najbardziej ogólnie można wyróżnić następujące klasy modeli:


- SIMO model typu jedno wejście, wiele wyjść (ang. Single Input Multiple Output),
- SISO model typu jedno wejście, jedno wyjście (ang. Single Input Single Output),
- MIMO model typu wiele wejść, wiele wyjść (ang. Multiple Input Multiple Output)
- MISO model typu wiele wejść, jedno wyjście (ang. Multiple Input Single Output)



Rys. 77. Podział modeli ze względu na liczbę wejść i wyjść

KONCEPCJA MODELU AUTOREGRESJI

Modelowanie autoregresyjne można wykorzystać podczas budowania modeli zjawisk dla których nie potrafimy znaleźć wystarczająco dobrze tłumaczących je praw nauki. Nie wiemy od czego zależą lub nie potrafimy wskazać wszystkich ich przyczyn. Model autoregresji opiera się założeniu, że obserwowane własności jakiegoś zjawiska można uporządkować według skali czasu. Zakłada się wówczas, że pewna liczba obserwacji historycznych wystarcza do określenia przyszłej obserwacji. Zaletami takiego podejścia jest możliwość rezygnacji z poszukiwania zmiennych objaśniających (niezależnych), ponieważ taką zmienną jest czas. Zaletą modelu autoregresji jest możliwość jego użycia dla różnych postaci modeli, zarówno konwencjonalnych jak również opartych na bazie wiedzy. Wadą modeli autoregresyjnych jest konieczność zgromadzenia odpowiednio liczego zbioru obserwacji .



Rys. 78. Idea modelu autoregresji

Najczęściej wykorzystywanymi modelami prognostycznymi przy założeniu odpowiednio liczego zbioru danych reprezentującego „historię” procesu jest ogólna klasa modeli autoregresji.

NA CZYM POLEGA METODA NAJMNIEJSZYCH KWADRATÓW

Metoda najmniejszych kwadratów (ang. least squares method LS) [Bilińska, Figwer, 1995] najpopularniejszą metodą estymacji parametrów modelu. Stosowana jest dla modeli statycznych i dynamicznych. Polega na dopasowaniu do punktów w przestrzeni wielowymiarowej funkcji o zadanych parametrach (powierzchni modelu). Dla funkcji liniowej, czyli typowej regresji jest to na przykład hiperpłaszczyzna. Dysponując obserwacją k wektorów zmiennych wejściowych i wyjściowych x_1, x_2, \dots, x_s, y w liczbie $1+s$ (zakładamy model MISO), formujemy je w następującą macierz

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & \dots & x_{1s} \\ 1 & x_{21} & x_{22} & \dots & \dots & x_{2s} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{i1} & x_{i2} & \dots & \dots & x_{is} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{k1} & x_{k2} & \dots & \dots & x_{ks} \end{bmatrix}, Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_i \\ \vdots \\ y_k \end{bmatrix}. \quad (7.9)$$

Dla powyższych macierzy należy dopasować powierzchnię modelu według kryterium najmniejszej sumy kwadratów błędów identyfikacji, co precyzuje wzór

$$\sum_{i=1}^k e_i^2 = \sum_{i=1}^k (y_i - \hat{y}_i)^2 = \min. \quad (7.10)$$

Warunek kryterium najmniejszych kwadratów w zapisie macierzowym jest następujący:

$$\min e^T \cdot e = \min (y - \hat{y})^T \cdot (y - \hat{y}) = \min (y - Xb)^T \cdot (y - Xb) \quad (7.11)$$

$$\frac{de^T e}{db} = 0 \quad (7.12)$$

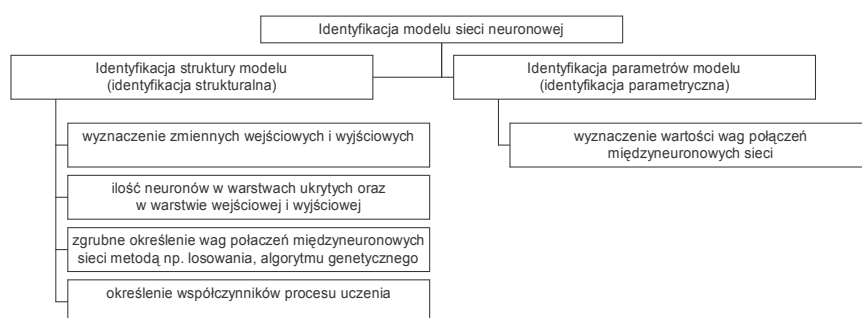
Minimum zachodzi po niezbędnych przekształceniach dla układu równań normalnych Gaussa, gdzie identyfikowane parametry są opisane wektorem b

$$X^T \cdot X \cdot b = X^T \cdot y, \quad (7.13)$$

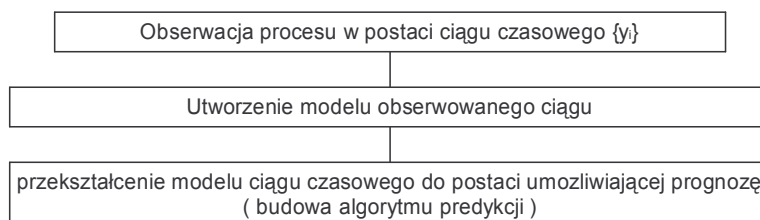
a rozwiązanie jest określone następująco

$$\hat{b} = (X^T X)^{-1} X^T y \quad (7.14)$$

IDENTYFIKACJA MODELI CIĄGÓW CZASOWYCH I MODELI OBIEKTÓW (ZJAWISK)



Znając model obiektu można określić jego zachowanie dla różnych wymuszeń pojawiających się na wejściu tego obiektu. Interesujące jest określenie przyszłego stanu obiektu dla czasu $t+n$, gdzie n stanowi horyzont prognozy, t zawiera historię zmian wejścia do chwili bieżącej. W procedurze progностycznej można wyróżnić następujące etapy przedstawione na.




Rys. 5. Etapy procedury progностycznej


W procesach niestacjonarnych konieczne jest aktualizacja estymat parametrów, warunek ten spełniają specjalne algorytmy predykcji w wersji **adaptacyjnej** (algorytmy rekurencyjne). Pozwalają one w czasie rzeczywistym dostosować wartości parametrów modelu do zmian zachodzących w obserwowanym procesie. Możliwe jest stosowanie prognozy **wielokrokowej**. Celem takiej prognozy jest określenie przebiegu procesu dla kolejno wzrastających horyzontów prognozy ($n=1,2, \dots, k$). Poprzez wykorzystanie dostępnych w momentach $t-n$ obserwacji ciągu czasowego (historii zmian stanu) jest możliwa próba określenia przyszłych wartości ciągu czasowego w momencie t oraz dalszych. Pozwala to na planowanie zadań eksploatacyjnych diagnostyce technicznej. W celu zapewnienia odpowiedniej wiarygodności prognoz należy określić jej jakość w sensie wybranych kryteriów subiektywnych (ocena wykresu). Można wtedy mówić prognozie o **najlepszej** jakości. Ponadto konieczne jest określenie **pewności** prognozy, przez którą rozumiemy ryzyko związane z niespełnieniem się postawionej prognozy. Jako miarę ryzyka można przyjąć odchylenie standardowe do okresu wyprzedzenia prognozy t . Pewność prognozy dla wyprzedzeń wielokrokowych zależy od liczby elementów w ciągu czasowym, który został użyty jako dane wejściowe (historyczne) i stosunku liczby tych próbek do wyprzedzenia prognozy. Dla dużych wartości tego stosunku jest możliwe osiągnięcie dobrej dokładności prognozy. Określone wartości tak zdefiniowanego stosunku zależą od konkretnych realizacji prognozowanego procesu.

IDENTYFIKACJA PRZEBIEGU SINUSOIDALNEGO

W celu pokazania na przykładach teorii dotyczącej procedur identyfikacji modeli autoregresyjnych zostaną zaprezentowane przykłady ilustrujące identyfikację elementarnych sygnałów.



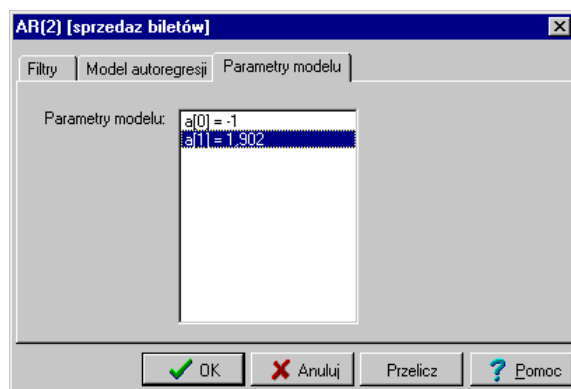
Rys. 79. Predykcja w oparciu o model AR(2)



Rys. 80. Predykcja w oparciu o model sieci neuronowej NAR(2)

Przeprowadzony eksperyment podczas identyfikacji danych wygenerowanych w oparciu o deterministyczny model funkcji sinus podczas testowania wykazały dużą bardzo dobre właściwości podczas predykcji i odtwarzania przebiegu źródłowego. Pomiar korelacji dla wydzielonego zbioru testowego o wartości 50 próbek wykazał zgodność na poziomie $k=1.0$ dla modelu AR(2) oraz $k=0.999$ dla modelu NAR(2). W przypadku liniowego modelu autoregresji uzyskujemy następujące równanie różnicowe

$$1 - 1.902z^{-1} + z^{-2} = 0 \quad (7.15)$$




Rys. 81. Parametry modelu AR(2)

Tabela 1. Przyjęte wartości parametrów sieci neuronowej podczas procesu uczenia

Parametry procesu uczenia sieci neuronowej	Wartości parametrów
--	---------------------

Współczynnik uczenia	0.9
Współczynniki momentu	0.7
Maksymalna wartość wag \pm	0.2
Rozmiar cyklu uczącego	1
Mieszanie wzorców	NIE



Rys. 82. Widok wykorzystanej sieci w procesie uczenia dla modelu o stosunkowo dużej liczbie parametrów (nadparametryzacja)

Tabela 1. Parametry modelu sieci neuronowej (por. rys. 77)

0.0233	-1.5484	-1.8665	-2.9007	-1.456	-1.3345
-0.0005	0	0.0002	0.0002	0.0001	0.0002
0 0	0	0	0	0	
-5.7577	2.8621				
-0.0002	-0.0002				
0 0					
0.3275	-0.3706				
0 0					
0 0					
3.631	-1.8315				
0.0001	0.0001				
0 0					
6.1435	-3.0945				
0.0001	0.0002				
0 0					
2.1634	-1.3987				
0 0.0001					
0 0					
2.585	-1.7222				
0.0001	0.0001				
0 0					
-2.108	-2.9124	-0.2733			
0.0002	0.0001	0.0005			
0 0	0				
-2.3177	0.045	1.5592	2.4946	0.8221	1.0571
0 0	0	0	0	0	
0 0	0	0	0	0	
-2.3659	0.0675	1.8363	3.2789	1.0624	1.1938
0 0	0	0	0	0	
0 0	0	0	0	0	
-3.2509	0.4869	1.6684	2.509	1.2256	1.538
0.0001	0	0.0001	0	0.0001	0.0001
0 0	0	0	0	0	
3.136	0.8732				
-0.0002	-0.0004				
0 0					
-1.9762	-2.9054	-0.9209			
0 0	-0.0001				
0 0	0				
-2.6083	-2.5447	-3.7361			

0	0	-0.0002
0	0	0
3.4407		
0.0007		
0		
-3.8704	-5.3585	
0.0005	0.0001	
0	0	

BŁĘDY PROGNOZY

	Zapis matematyczny miary	Interpretacja miary
MIARY LINIOWE	$R^2 = \frac{n \cdot \sum_{t=1}^n y_t \cdot \hat{y}_t - \sum_{t=1}^n y_t \cdot \sum_{t=1}^n \hat{y}_t}{\left[\sum_{t=1}^n y_t^2 - \left(\sum_{t=1}^n y_t \right)^2 \right] \cdot \left[\sum_{t=1}^n \hat{y}_t^2 - \left(\sum_{t=1}^n \hat{y}_t \right)^2 \right]}$	Wartość r-kwadrat można interpretować jako część wariancji y przypisywalną wariancji x.
	$r = \frac{n \cdot \sum_{t=1}^n y_t \cdot \hat{y}_t - \sum_{t=1}^n y_t \cdot \sum_{t=1}^n \hat{y}_t}{\sqrt{\left[\sum_{t=1}^n y_t^2 - \left(\sum_{t=1}^n y_t \right)^2 \right] \cdot \left[\sum_{t=1}^n \hat{y}_t^2 - \left(\sum_{t=1}^n \hat{y}_t \right)^2 \right]}}$	Oblicza współczynnik korelacji liniowej Pearsona r. Jest to bezwymiarowy wskaźnik, którego wartość mieści się w zakresie od -1,0 do 1,0 włącznie, i odzwierciedla stopień liniowej zależności pomiędzy dwoma zbiorami danych.
	$BIAS = \frac{\sum_{t=1}^n (y_t - \hat{y}_t)}{n}$	Bezwzględny średni błąd prognozy
	$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{ y_i - \hat{y}_i }{y_i}$	(ang. Mean-Absolute Percentage Error) Średni względny błąd prognozy
	$RMS = \sqrt{\frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{n}}$	Średni kwadratowy błąd prognozy (błąd standardowy)
	$\phi^2 = \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y}_t)^2} = 1 - R^2$	Współczynnik zbieżności

Literatura

- [Bilińska, Figwer, 1995] Bilińska E, Figwer J.: *Analiza, identyfikacja i predykcja ciągów czasowych*. Skrypt Politechniki Śląskiej nr 1923, Gliwice 1995.
- [Box, Jenkins, 1983] Box G.E.P., Jenkins G.M.: *Analiza szeregów czasowych. Prognozowanie i sterowanie*. PWN, Warszawa 1983.
- [Niederliński A., Kasprzyk J., Figwer J., 1997] Niederliński A., Kasprzyk J., Figwer J.: *Multi-Edip analizator wielowymiarowych sygnałów i obiektów*. Wydawnictwo Politechniki Śląskiej, Gliwice 1997.